

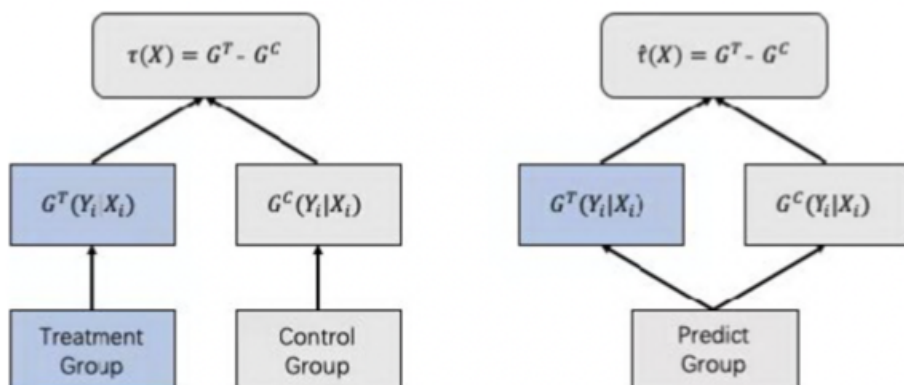
# uplift相关

- 相关理论
  - two model方法
  - one model方法
    - 基于转换的方法
    - transformed outcome方法
    - class transform方法
  - 直接对uplift建模
- 评估方法
  - Qini系数
  - AUUC
- 应用

参考 uplift详细说明

## 相关理论

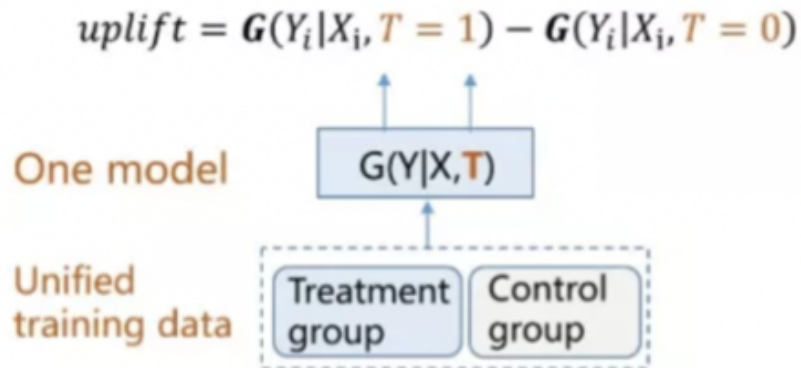
### two model方法



单独对treatment样本和control样本分别训一个模型

在线对于候选样本估出两个的g，相减得到的结果拿来排序，高的出优惠券，低的不出之类的

## one model方法



输入两种样本，T作为特征，目标是给定是否treat(T是否=1)的时候的Y。

训完后，要估uplift值还得自己算一下 $G(Y|X, T=1) - G(Y|X, T=0)$

## 基于转换的方法

### transformed outcome方法

对于样本不均衡的情况，

W表示是否被选中去treat，被选中去treat的概率为 $p = P(w=1)$

那么直接学习 $Y^*$ 就行了，因为经过推导， $Y^*$ 的期望和uplift是等价的====>所以训一个模型去回归 $Y^*$ 就行了

而当 $p=0.5$ 的时候，就转化成了下面这个  $-2 \ 2 \ 0 \ 0$  的矩阵（把 $p=0.5$ 代入 $Y^*$ 的式子就是了）

## The Transformed Outcome

Our package by default implements the Transformed Outcome (Athey 2016) method, defined as:

$$Y^* = Y \frac{W - p}{p(1 - p)}$$

where  $Y^*$  is the Transformed Outcome,  $Y$  is the outcome (1 or 0),  $W$  indicates the presence of a treatment (1 or 0), and  $p = P(W = 1)$  (the treatment policy). When  $p = 0.5$ , this amounts to labelling (treatment, outcome) pairs as follows:

Outcome label	Yes	No
	-2	2
Treatment label	Control	Treat
	0	0

The beauty of this transformation is that, in expectation,

$$E[Y^*] = P(Y|W = 1) - P(Y|W = 0),$$

or uplift. Any algorithm trained to predict  $Y^*$ , then, gives a prediction of uplift.

## class transform方法

假设 $p=0.5$ ，且 $G$ 和 $X$ 是独立的

### 3.2. The Class Transformation Method

The **Class Transformation** method was introduced by [Jaskowski and Jaroszewicz \(2012\)](#) in the case of binary outcome variable ( $Y_i^{obs} = \{0, 1\}$ ). The method consists in creating the following target variable:

$$\rightarrow Z_i = Y_i^{obs}W_i + (1 - Y_i^{obs})(1 - W_i) \quad (6)$$

The new target,  $Z_i$ , is therefore equal to one in either following cases: **1)** the observation belongs to the treatment group and  $Y_i^{obs} = 1$  or **2)** the observation belongs to the control group and  $Y_i^{obs} = 0$ . In all other cases, the target takes on value zero.

Under the assumption that control and treated groups are balanced across all profiles of individual (that is,  $p(X_i = x) = 1/2$  for all  $x$ ), ([Jaskowski and Jaroszewicz \(2012\)](#)) proved that:

$$\tau(X_i) = 2P(Z_i = 1|X_i) - 1 \quad (7)$$

Uplift modeling thus boils down to modeling  $P(Z_i = 1|X_i)$ , (i.e.  $E[Z_i = 1|X_i]$ ). The Class Transformation method is popular because it tends to perform better than the Two-Model approach while still remaining simple; any off-the-shelf classifier can be used to model  $E[Z_i = 1|X_i]$ . However, the two assumptions (binary outcome variable and balanced dataset

也就是

定义一个变量  $G \in \{T, C\}$ ,  $G = T$ 表示有干预，即实验组（treatment）， $G = C$ 表示无干预，即对照组（control）。uplift分数  $\tau$  可以表示为：

$$\begin{aligned}\tau(\mathbf{X}) &= P(Y = 1|\mathbf{X}, G = T) - P(Y = 1|\mathbf{X}, G = C) \\ &= P^T(Y = 1|\mathbf{X}) - P^C(Y = 1|\mathbf{X})\end{aligned}\tag{5}$$

上式中  $\mathbf{X}$  表示用户特征， $P^T$  表示用户在实验组中下单的概率（输出结果为positive）， $P^C$  表示用户在对照组中下单的概率（输出结果也为positive），uplift score 就是两个概率的差值。

为了统一表示实验组和对照组都下单的情况（ $Y = 1$ ），再定义一个变量  $Z$ ,  $Z \in \{0, 1\}$ ：

$$Z = \begin{cases} 1 & \text{if } G = T \text{ and } Y = 1 \\ 1 & \text{if } G = C \text{ and } Y = 1 \\ 0 & \text{otherwise} \end{cases}$$

下面证明优化(5)式相当于优化  $P(Z = 1|\mathbf{X})$ 。

这样就可以直接转化为一个二分类问题直接搞

## 直接对uplift建模

可以直接用树、svm、LR啥的直接搞，太复杂了看不懂

## 评估方法

## Qini系数

对所有测试集的用户，用模型预估出来的uplift值从高到低排序，根据用户数占比10%，20%...100%分成十份，每一份里计算

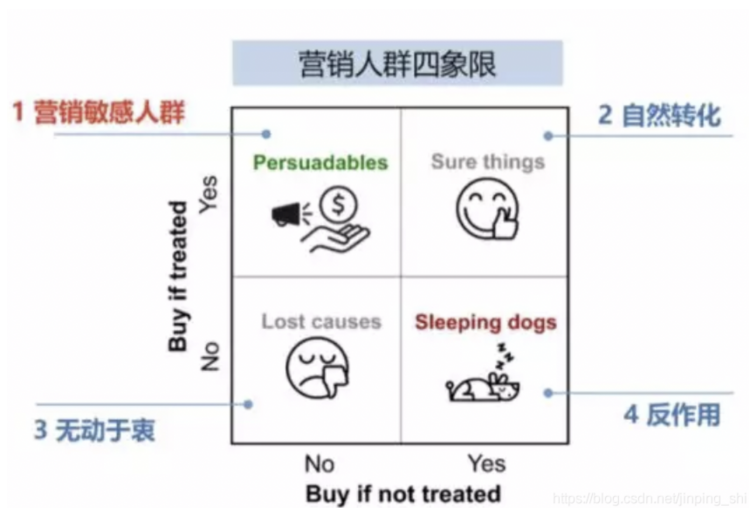
$$Q(i) = \frac{n_{t,y=1}(i)}{N_t} - \frac{n_{c,y=1}(i)}{N_c} \quad i = 10\%, 20\%, \dots 100\%$$

treatment里真实label=1的用户比例减掉control里真实label=1的比例

## AUUC

画出Qini曲线后，看曲线下面积

## 应用



1. 心潮默认v.s.不出心潮，得不到矩阵第二列数据(buy if not treated--->yes)

2. 心潮默认v.s.切频道，抽一批切频道用户，空转都是切频道，实验一半切成默认。根据效果搞一个模型，对全量切频道用户打分，top的抽一部分，搞成默认，看一下效果是否符合预期。具体方案细节待定。风险：目前切频道dau就37w左右，圈定的切频道目标用户有6000w，一是抽用户的时候是否要从这部分dau里也抽一部分，二是不确定实际收益会有多少。

3. 在push、优惠券等场景用uplift，可以在不同场景下（例如不同时间段）给同一个用户推多或者推少或者不推，是一个动态的过程，但我们这个场景可能不一定适合，例如一个用户今天默认，明天又切频道了，过两天又默认，用户体验问题比较大。