Contents

1 多模态（图像） 3

1.1 VLM 导论 . . . 3
1.2 vilbert . . . 3
1.3 VLbert . . . 3
1.4 CLIP 系列 . . . 3
1.5 cn-clip . . . 3
1.6 BEiT 系列 . . . 4
1.6.1 BEiT . . . 4
1.6.2 BEiT v2 . . . 4
1.6.3 BEiT v3 . . . 4
1.7 ViT&Swin-Transformer . . . 4
1.8 像素 tokenizer . . . 4
1.9 stable diffusion . . . 4
1.10 stable diffusion 3 . . . 5
1.11 DALL-E 系列 . . . 5
1.12 PALM-E . . . 6
1.13 InstantID . . . 6
1.14 VAR . . . 6
1.15 cobra . . . 6
1.16 Hyper-SD . . . 7
1.17 TextSquare . . . 7
1.18 neural network diffusion . . . 7
1.19 hunyuan-dit . . . 7
1.20 lumina-t2x . . . 7
1.21 Vision-LSTM . . . 7
1.22 CSR . . . 7
1.23 ManyICL . . . 7
1.24 MAR . . . 7
1.25 Cambrian-1 . . . 8
1.26 VCR . . . 8
1.27 EVE . . . 8
1.28 LC-Mis . . . 8
1.29 多模态 cot . . . 8
1.30 Imagen 3 . . . 8
1.31 Chameleon . . . 8
1.32 Show-o . . . 8
1.33 Transfusion . . . 9
1.34 ControlNeXt . . . 9
1.35 GNN+Graph Transformer 综述 . . . 9
1.36 Llip . . . 9
1.37 longllava . . . 9
1.38 Molmo . . . 10
1.39 Playground . . . 10
1.40 REPA . . . 10
1.41 LLaVA-Critic . . . 10
1.42 MM1.5 . . . 10
1.43 SCMs . . . 10
1.44 Janus . . . 10
1.45 OmniGen . . . 10
1.46 LLM2CLIP . . . 11
1.47 TFG . . . 11
1.48 Deepseek-VL2 . . . 11

1.49 Florence-VL . . . 11
1.50 metamorph . . . 11
1.51 多模态推荐系统 . . . 11
1.52 其他 . . . 11

2 多模态（视频） 12
2.1 videobert . . . 12
2.2 video caption . . . 12
2.3 视频 tokenizer 方法 . . . 12
2.4 SORA . . . 13
2.4.1 现有方法 . . . 14
2.4.2 将视频转成 spacetime latent patches . . . 14
2.4.2.1 Vivit . . . 14
2.4.2.2 latent 空间上的 patch . . . 15
2.4.3 Diffusion Transformer . . . 16
2.4.4 语言理解 . . . 16
2.4.5 使用图像/视频作为 prompt . . . 16
2.4.6 生成图像 . . . 16
2.4.7 涌现的模拟能力 . . . 17
2.4.8 存在的问题 . . . 17
2.5 open-sora（Colossal-AI） . . . 17
2.5.1 模型架构 . . . 17
2.5.1.1 VAE 部分 . . . 17
2.5.1.2 生成部分 . . . 18
2.5.1.3 训练 . . . 18
2.6 open-sora(北大版) . . . 19
2.7 MORA . . . 19
2.8 minigpt4-video . . . 19
2.9 mini-gemini . . . 19
2.10 Vidu . . . 20
2.11 Vidu 1.5 . . . 20
2.12 gen-3 . . . 20
2.13 可灵 . . . 20
2.14 V2A . . . 21
2.15 长视频 LongVA . . . 21
2.16 LONGVILA . . . 21
2.17 liveportrait . . . 21
2.18 diffusion forcing . . . 21
2.19 VideoSys . . . 21
2.19.1 Pyramid Attention Broadcast (PAB) . . . 21
2.19.2 Dyanmic Sequence Parallelism（DSP） . . . 21
2.20 GameNGen . . . 21
2.21 Firefly . . . 22
2.22 MovieGen . . . 22
2.23 EMOVA . . . 22
2.24 LLaVA-Video . . . 22
2.25 Emu3 . . . 22
2.26 hunyuan-video . . . 22
2.27 STIV . . . 22
2.28 Veo 2 . . . 22
2.29 通义万相 . . . 22
2.30 其他 . . . 23

1 多模态（图像）

【IEEE Fellow 何晓东 & 邓力】多模态智能论文综述：表示学习，信息融合与应用，259 篇文献带你了解 AI 热点技

Multimodal Intelligence: Representation Learning, Information Fusion, and Applications

BERT 在多模态领域中的应用

1.1 VLM 导论

视觉语言模型导论：这篇论文能成为你进军 VLM 的第一步

An Introduction to Vision-Language Modeling

1.2 vilbert

ViLBERT: Pretraining Task-Agnostic Visiolinguistic Representations for Vision-and-Language Tasks

研究人员提出了一种名为 ViLBERT（图文 BERT）模型。这是一个可以学习任务未知的、图像内容和自然语言联合表征的模型。研究人员将流行的 BERT 架构扩展成一个 multi-modal two-stream 模型上。在这个模型上，模型用两个分开的流处理图像和文本输入，但他们彼此用联合注意力层交互。研究人员在两个代理任务上，使用 Conceptual Captions 数据集（数据集很大，而且是自动收集的数据）预训练这个模型，然后将模型秦阿姨到多个建立好的图像-文本任务上。这些任务包括图像问答、图像常识推理、引述表达、指称成分，以及基于捕捉的图像提取。这些只需要在基本架构上进行微小的补充。研究人员观察到，相比现有的针对任务的特定模型，新模型在这些任务上都有了相助的性能提升———在每个任务上都取得了 SOTA。

1.3 VLbert

Visual-Linguistic BERT，简称 VL-BERT

微软亚研提出 VL-BERT：通用的视觉-语言预训练模型

此预训练过程可以显著提高下游的视觉-语言任务的效果，包含视觉常识推理、视觉问答与引用表达式理解等。值得一提的是，在视觉常识推理排行榜中，VL-BERT 取得了当前单模型的最好效果。

VL-BERT: Pre-training of Generic Visual-Linguistic Representations

之前的视觉-语言模型分别使用计算机视觉或自然语言处理领域中的预训练模型进行初始化，但如果目标任务数据量不足，模型容易过拟合从而损失性能。并且对于不同的视觉-语言任务，其网络架构一般是经过特殊设计的，由此很难通过视觉-语言联合预训练的过程帮助下游任务。

VL-BERT 的主干网络使用 TransformerAttention 模块，并将视觉与语言嵌入特征作为输入，其中输入的每个元素是来自句子中的单词、或图像中的感兴趣区域（Region of Interests，简称 RoIs）。在模型训练的过程中，每个元素均可以根据其内容、位置、类别等信息自适应地聚合来自所有其他元素的信息。在堆叠多层 TransformerAttention 模块后，其特征表示即具有更为丰富的聚合与对齐视觉和语言线索的能力。

为了更好地建模通用的视觉-语言表示，作者在大规模视觉-语言语料库中对 VL-BERT 进行了预训练。采用的预训练数据集为图像标题生成数据集，Conceptual Captions，其中包含了大约 330 万个图像标题对。

VL-BERT 的预训练主要采用三个任务：＋屏蔽语言模型（Masked Language Modeling），即随机屏蔽掉语句中的一些词，并预测当前位置的词是什么；＋屏蔽 RoI 分类（MaskedRoIClassification），即随机屏蔽掉视觉输入中的一些 RoIs，并预测此空间位置对应 RoI 的所属类别；＋图像标题关联预测（Sentence-Image Relationship Prediction），即预测图像与标题是否属于同一对。

在预训练结束后，使用微调来进行下游任务的训练。本文中主要在三个视觉-语言下游任务中进行微调，即视觉常识推理（VisualCommonsenseReasoning）、视觉问答（VisualQuestionAnswering）与引用表达式理解（ReferringExpressionComprehension），下面将分别介绍。

视觉常识推理任务即给定图片与相关问题，机器不仅需要回答问题，还需要提供理由来证明答案的正确性。此任务（Q->AR）被分解为两个子任务，即视觉问答（Q->A，给定图片与问题，输出正确答案），以及视觉推理（QA->R，给定图片、问题与答案，输出正确的理由）。

1.4 CLIP 系列

1.5 cn-clip

Chinese CLIP: Contrastive Vision-Language Pretraining in Chinese

https://github.com/OFA-Sys/Chinese-CLIP

1.6 BEiT 系列

1.6.1 BEiT

BEIT: BERT Pre-Training of Image Transformers

1.6.2 BEiT v2

BEIT V2: Masked Image Modeling with Vector-Quantized Visual Tokenizers

1.6.3 BEiT v3

Image as a Foreign Language: BEIT Pretraining for All Vision and Vision-Language Tasks

1.7 ViT&Swin-Transformer

SwinTransformer 与 Vit 细节总结

An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale

对于一张 $224 \times 224 \times 3$ 的图像，假设每个 patch 是 16×16，那就分成 $\frac{224\times224}{16\times16} = 196$ 个 patch(即 $seq_length = 196$)，每个 patch 的维度是 $16 \times 16 \times 3 = 768$，最后加上 [CLS] 这个 token，就是 $seq_length = 197$。

1.8 像素 tokenizer

Meta 新研究挑战 CV 领域基操：ViT 根本不用 patch，用像素做 token 效果更佳

An Image is Worth More Than 16x16 Patches: Exploring Transformers on Individual Pixels

1.9 stable diffusion

High-Resolution Image Synthesis with Latent Diffusion Models

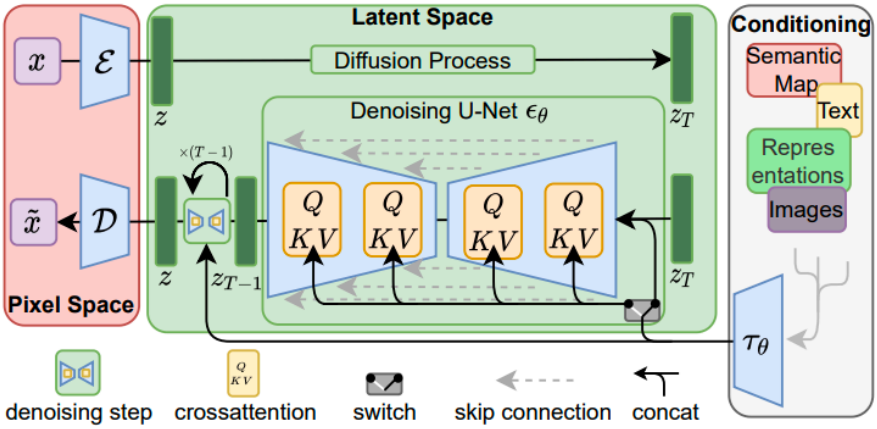

- 输入图像，经过编码器得到 z，z 通过前向扩散不断加噪声得到 z_T（正向扩散）
- 输入条件，经过条件编码器 (原文是 BERT，到了 DALL-E2 就改成 CLIP 了) 得到 τ_θ
- z_T 在 τ_θ 的指导下不断去噪（反向扩散），得到新的 z，再通过解码器得到最终生成的图像

其中的正向扩散和反向扩散一般用 U-Net

代码库：https://github.com/CompVis/latent-diffusion/tree/main

粗略看了下代码，带 condition 的训练原理大概是训练语料中有图 + 文本（例如 imagenet 的 class_label，这里可以映射到一个 classid 也可以直接拿明文），然后 condition 和图片一起作为输入去训练 auto-eocnder 和 ldm

在`/latent-diffusion/ldm/data/imagenet.py` 这个代码里，把 class_label 加进来了

```
    def _load(self):
        with open(self.txt_filelist, "r") as f:
            self.relpaths = f.read().splitlines()
            l1 = len(self.relpaths)
            self.relpaths = self._filter_relpaths(self.relpaths)
            print("Removed {} files from filelist during filtering.".format(l1 - len(self.relpaths)))

        self.synsets = [p.split("/")[0] for p in self.relpaths]
        self.abspaths = [os.path.join(self.datadir, p) for p in self.relpaths]

        unique_synsets = np.unique(self.synsets)
        class_dict = dict((synset, i) for i, synset in enumerate(unique_synsets))
        if not self.keep_orig_class_label:
            self.class_labels = [class_dict[s] for s in self.synsets]
        else:
            self.class_labels = [self.synset2idx[s] for s in self.synsets]

        with open(self.human_dict, "r") as f:
            human_dict = f.read().splitlines()
            human_dict = dict(line.split(maxsplit=1) for line in human_dict)

        self.human_labels = [human_dict[s] for s in self.synsets]

        labels = {
            "relpath": np.array(self.relpaths),
            "synsets": np.array(self.synsets),
            "class_label": np.array(self.class_labels),
            "human_label": np.array(self.human_labels),
        }

        if self.process_images:
            self.size = retrieve(self.config, "size", default=256)
            self.data = ImagePaths(self.abspaths,
                                   labels=labels,
                                   size=self.size,
                                   random_crop=self.random_crop,
                                   )
        else:
            self.data = self.abspaths
```

1.10 stable diffusion 3

Stable Diffusion 3 论文终于发布，架构细节大揭秘，对复现 Sora 有帮助?

1.11 DALL-E 系列

DALL-E3:

Improving Image Generation with Better Captions

现有的文本-> 图像模型面临的一个基本问题是：训练数据集中的文本-图像 pair 对中的**文本质量较差**。

- 学习一个图像文本生成器，可以生成详细、准确的图像描述
- 将此文本生成器应用到数据集以生成更详细的文本
- 在改进的数据集上训练文本 - 图像模型

1.12 PALM-E

PaLM-E: An Embodied Multimodal Language Model

1.13 InstantID

InstantID: Zero-shot Identity-Preserving Generation in Seconds

https://github.com/InstantID/InstantID

小红书开源「InstantID」效果炸裂，迅速蹿上 Github 热榜

用户只需上传一张照片，就能轻松定制出多种风格的 AI 写真

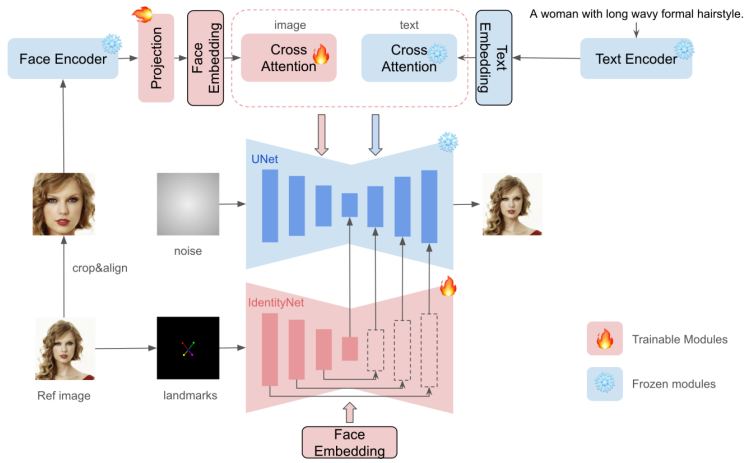

曾爆火的 InstantID 又有了新玩法：风格化图像生成，已开源

InstantStyle: Free Lunch towards Style-Preserving in Text-to-Image Generation

https://github.com/InstantStyle/InstantStyle

1.14 VAR

GPT 超越扩散、视觉生成 Scaling Law 时刻！北大 & 字节提出 VAR 范式

Visual Autoregressive Modeling: Scalable Image Generation via Next-Scale Prediction

https://github.com/FoundationVision/VAR

1.15 cobra

首个基于 Mamba 的 MLLM 来了！模型权重、训练代码等已全部开源

Cobra: Extending Mamba to Multi-Modal Large Language Model for Efficient Inference

https://github.com/h-zhao1997/cobra

1.16 Hyper-SD

加速扩散模型，最快 1 步生成 SOTA 级图片，字节 Hyper-SD 开源了

Hyper-SD: Trajectory Segmented Consistency Model for Efficient Image Synthesis

1.17 TextSquare

8B 文字多模态大模型指标逼近 GPT4V，字节、华师、华科联合提出 TextSquare

TextSquare: Scaling up Text-Centric Visual Instruction Tuning

1.18 neural network diffusion

用扩散模型生成网络参数，LeCun 点赞尤洋团队新研究

Neural Network Diffusion

https://github.com/NUS-HPC-AI-Lab/Neural-Network-Diffusion

1.19 hunyuan-dit

首个中文原生 DiT 架构！腾讯混元文生图大模型全面开源，免费商用

1.20 lumina-t2x

DiT 架构大一统：一个框架集成图像、视频、音频和 3D 生成，可编辑、能试玩

Lumina-T2X: Transforming Text into Any Modality, Resolution, and Duration via Flow-based Large Diffusion Transformers

https://github.com/Alpha-VLLM/Lumina-T2X

https://huggingface.co/Alpha-VLLM/Lumina-T2I/tree/main

1.21 Vision-LSTM

原作者带队，LSTM 卷土重来之 Vision-LSTM 出世

Vision-LSTM: xLSTM as Generic Vision Backbone

https://nx-ai.github.io/vision-lstm/

1.22 CSR

零成本突破多模态大模型瓶颈！多所美国顶尖高校华人团队，联合推出自增强技术 CSR

Calibrated Self-Rewarding Vision Language Models

https://github.com/YiyangZhou/CSR

1.23 ManyICL

吴恩达团队新作：多模态多样本上下文学习，无需微调快速适应新任务

Many-Shot In-Context Learning in Multimodal Foundation Models

1.24 MAR

何恺明新作再战 AI 生成：入职 MIT 后首次带队，奥赛双料金牌得主邓明扬参与

Autoregressive Image Generation without Vector Quantization

1.25 Cambrian-1

寒武纪 1 号诞生：谢赛宁 Yann LeCun 团队发布最强开源多模态 LLM

Cambrian-1: A Fully Open, Vision-Centric Exploration of Multimodal LLMs

https://github.com/cambrian-mllm/cambrian

https://huggingface.co/nyu-visionx/

https://huggingface.co/datasets/nyu-visionx/CV-Bench

https://github.com/cambrian-mllm/cambrian

当前多模态学习研究的两个潜在问题：

- 过度且过早地依赖语言，这是一个捷径，能弥补学习有效视觉表征的不足之处
- 现有基准可能无法为真实世界场景提供足够的指导 ——— 视觉定基对于稳健的多模态理解至关重要

1.26 VCR

Bengio 团队提出多模态新基准，直指 Claude 3.5 和 GPT-4o 弱点

VCR: Visual Caption Restoration

https://github.com/tianyu-z/VCR

1.27 EVE

抛弃视觉编码器，这个「原生版」多模态大模型也能媲美主流方法

Unveiling Encoder-Free Vision-Language Models

https://github.com/baaivision/EVE

1.28 LC-Mis

AI 画家的「滑铁卢」：为什么冰可乐不愿意住进茶杯里？

Lost in Translation: Latent Concept Misalignment in Text-to-Image Diffusion Models

1.29 多模态 cot

ACL 2024 Oral ｜我们离真正的多模态思维链推理还有多远？

1.30 Imagen 3

Imagen 3

Imagen 3 支持人物生成，人人可用！谷歌 Gemini AI 重大升级来了

https://deepmind.google/technologies/imagen-3/

1.31 Chameleon

下面 3 个工作都在这里有介绍：生成-理解大一统：一文浅谈多模态大模型最新研究进展

Meta 首发「变色龙」挑战 GPT-4o，34B 参数引领多模态革命！10 万亿 token 训练刷新 SOTA

Chameleon: Mixed-Modal Early-Fusion Foundation Models

1.32 Show-o

Show-o: One Single Transformer to Unify Multimodal Understanding and Generation

1.33 Transfusion

(toread)

统一 transformer 与 diffusion！Meta 融合新方法剑指下一代多模态王者

Transfusion: Predict the Next Token and Diffuse Images with One Multi-Modal Model

一般来说，多模态生成模型需要能够感知、处理和生成离散元素（如文本或代码）和连续元素（如图像、音频和视频数据）。

- 离散模态领域：以预测下一个词为目标的语言模型占据主导地位
- 连续模态方面：扩散模型及其泛化形式则是当前最先进技术

研究者一直试图将语言模型与扩散模型结合：

- 方法一：直接扩展语言模型，使其能够利用扩散模型作为一个工具，或者将一个预训练的扩散模型嫁接到语言模型上。
- 方法二：是对连续模态进行量化处理，然后在离散的 token 上训练一个标准的语言模型，虽然简化了模型架构，但也会造成信息的丢失。

本文通过训练单个模型来预测离散文本 token 和扩散连续图像，从而实现两种模态的完全集成，且不会丢失任何信息。引入了一个训练模型的新方法 Transfusion，能够无缝地生成离散和连续的模态，将语言模型损失函数与扩散相结合，在混合模态序列上训练单个 transformer。

该研究还在文本和图像数据混合基础上从头开始预训练多个 Transfusion 模型，最多可达到 7B 参数量，并针对各种单模态和跨模态基准建立扩展定律。

1.34 ControlNeXt

视频生成控制提升几十倍，新一代轻量级 ControlNeXt 火了，贾佳亚团队正挑战 Scaling Law

ControlNeXt: Powerful and Efficient Control for Image and Video Generation

https://github.com/dvlab-research/ControlNeXt

1.35 GNN+Graph Transformer 综述

TPAMI 2024 | 计算机视觉中基于图神经网络和图 Transformers 的方法和最新进展

Survey on Graph Neural Networks and Graph Transformers in Computer Vision: A Task-Oriented Perspective

1.36 Llip

ICML 2024 | 直面 CLIP 内在缺陷，Meta 提出全新 latent 对比预训练框架 Llip

Modeling Caption Diversity in Contrastive Vision-Language Pretraining

基于对比视觉-语言预训练技术的大型多模态模型目前已成为人工智能领域研究的热点课题。但这一预训练技术仍然以经典的 CLIP 模型为基础，缺乏进一步的发展。此外，鉴于 CLIP 模型通过将图像及其 caption 映射到单个向量这样的底层机制，可以认为限制了对比预训练模型描述图像各种其他方面的能力。

提出了一种名为 Llip 的架构（Latent Language Image Pretraining），以图像字幕生成（Image Caption）任务作为出发点，用来模拟自然场景中与单张图像进行匹配 caption 的多样性。Llip 仍然采用双塔特征提取模式，其视觉编码器可以对给定图像输出一组视觉特征，这些特征可以总结与当前图像匹配的多样式 captions 中的文本信息，来得到最终的表示。

1.37 longllava

首个 Mamba+Transformer 混合架构多模态大模型来了，实现单卡千图推理

LongLLaVA: Scaling Multi-modal LLMs to 1000 Images Efficiently via Hybrid Architecture

https://github.com/FreedomIntelligence/LongLLaVA

1.38 Molmo

号称击败 Claude 3.5 Sonnet，媲美 GPT-4o，开源多模态模型 Molmo 挑战 Scaling law

Molmo and PixMo: Open Weights and Open Data for State-of-the-Art Multimodal Models

1.39 Playground

文生图参数量升至 240 亿！Playground v3 发布：深度融合 LLM，图形设计能力超越人类

Playground v3: Improving Text-to-Image Alignment with Deep-Fusion Large Language Models

1.40 REPA

扩散模型训练方法一直错了！谢赛宁：Representation matters

Representation Alignment for Generation: Training Diffusion Transformers Is Easier Than You Think

https://github.com/sihyun-yu/REPA

1.41 LLaVA-Critic

Evaluation is All You Need！首个开源多模态大模型通用评测器 LLaVA-Critic

LLaVA-Critic: Learning to Evaluate Multimodal Models

1.42 MM1.5

苹果多模态模型大升级！文本密集、多图理解，全能小钢炮

MM1.5: Methods, Analysis & Insights from Multimodal LLM Fine-tuning

1.43 SCMs

OpenAI 攻克扩散模型短板，清华校友路橙、宋飏合作最新论文

刚刚，OpenAI 发布 sCM 提升 50 倍效率，扩散模型重大技术突破！

比扩散模型快 50 倍！OpenAI 发布多模态模型实时生成进展，作者还是清华校友，把休假总裁 Greg 都炸出来了

Simplifying, Stabilizing & Scaling Continuous-Time Consistency Models

1.44 Janus

DeepSeek 新作 Janus：解耦视觉编码，引领多模态理解与生成统一新范式

Janus: Decoupling Visual Encoding for Unified Multimodal Understanding and Generation

https://github.com/deepseek-ai/Janus

https://huggingface.co/spaces/deepseek-ai/Janus-1.3B

1.45 OmniGen

新扩散模型 OmniGen 一统图像生成，架构还高度简化、易用

OmniGen: Unified Image Generation

https://github.com/VectorSpaceLab/OmniGen

1.46 LLM2CLIP

跨模态大升级！少量数据高效微调，LLM 教会 CLIP 玩转复杂文本

LLM2CLIP: POWERFUL LANGUAGE MODEL UNLOCKS RICHER VISUAL REPRESENTATION

https://github.com/microsoft/LLM2CLIP

1.47 TFG

NeurIPS Spotlight | 从分类到生成：无训练的可控扩散生成

TFG: Unified Training-Free Guidance for Diffusion Models

https://github.com/YWolfeee/Training-Free-Guidance

1.48 Deepseek-VL2

久等了，DeepSeek-VL2

https://github.com/deepseek-ai/DeepSeek-VL2

DeepSeek-VL2: Mixture-of-Experts Vision-Language Models for Advanced Multimodal Understanding

- 数据：比一代 DeepSeek-VL 多一倍优质训练数据，引入梗图理解、视觉定位、视觉故事生成等新能力
- 架构：视觉部分使用切图策略支持动态分辨率图像，语言部分采用 MoE 架构低成本高性能
- 训练：继承 DeepSeek-VL 的三阶段训练流程，同时通过负载均衡适配图像切片数量不定的困难，对图像和文本数据使用不同流水并行策略，对 MoE 语言模型引入专家并行，实现高效训练

1.49 Florence-VL

Florence-VL 来了！使用生成式视觉编码器，重新定义多模态大语言模型视觉信息

Florence-VL: Enhancing Vision-Language Models with Generative Vision Encoder and Depth-Breadth Fusion

https://github.com/JiuhaiChen/Florence-VL

1.50 metamorph

统一视觉理解与生成，MetaMorph 模型问世，LeCun、谢赛宁、刘壮等参与

MetaMorph: Multimodal Understanding and Generation via Instruction Tuning

1.51 多模态推荐系统

多模态推荐系统新突破，一文读懂前沿进展！

Multimodal Recommender Systems: A Survey

https://github.com/Applied-Machine-Learning-Lab/Awesome-Multimodal-Recommender-Systems

BM3：Bootstrap Latent Representations for Multi-modal Recommendation

EM3：End-to-end training of Multimodal Model and ranking Model

Multimodal Pretraining, Adaptation, and Generation for Recommendation: A Survey.. KDD24

1.52 其他

(toread)

近期必看的多模态大模型进展：从 Qwen2-VL 到 Pixtral

2 多模态（视频）

2.1 videobert

通过未标记视频进行跨模态时间表征学习

VideoBERT: A Joint Model for Video and Language Representation Learning，VideoBert 模型。

2.2 video caption

Tarsier: Recipes for Training and Evaluating Large Video Description Models

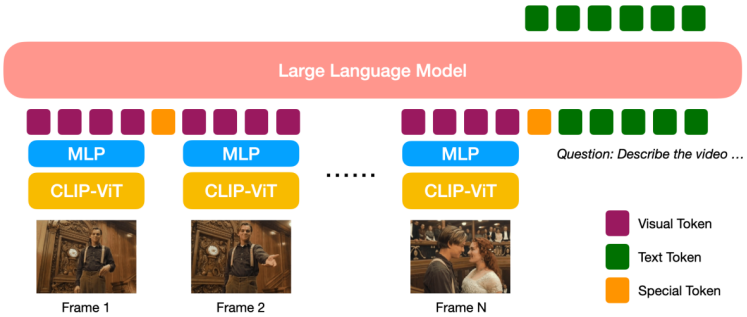

Figure 2: Tarsier model architecture. We use a frozen CLIP-ViT to encode frames, then project them to the LLM token space through an MLP. The LLM is then trained with the next-token prediction loss. (Source movie: *Titanic, 1997*)

2.3 视频 tokenizer 方法

- VideoGPT：Videogpt: Video generation using vq-vae and transformers，结合了 VQ-VAE，而且是自回归的 transformer
- magvit：MAGVIT: Masked Generative Video Transformer
- magvitv2：Language Model Beats Diffusion – Tokenizer is Key to Visual Generation，语言模型战胜扩散模型！谷歌提出 MAGVIT-v2：视频和图像生成上实现双 SOTA！

先看 vq 的改进版：

Finite Scalar Quantization: VQ-VAE Made Simple提出了 fsq，码本大小是 $|C| = L^d$

magvit-v2 提出了 LFQ，也优化了 vq-vae

BSQ：Image and Video Tokenization with Binary Spherical Quantization

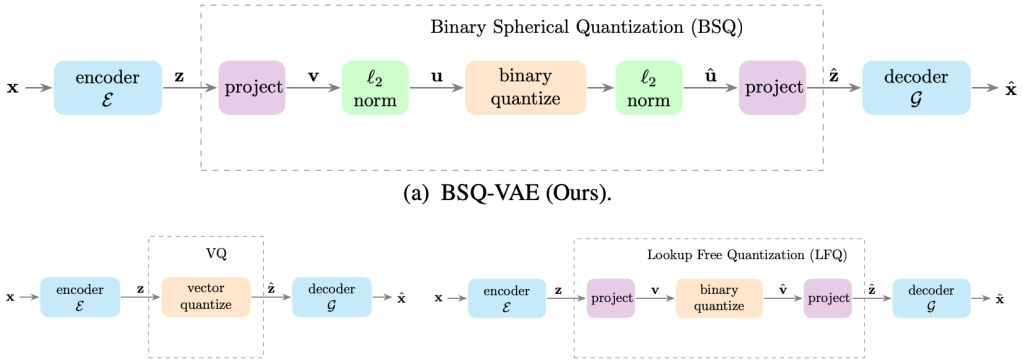

(a) BSQ-VAE (Ours).

(b) VQ-VAE. (c) LFQ-VAE.

Figure 1: **Variational Auto-Encoders (VAE) with different bottlenecks (BSQ, VQ, and LFQ).**

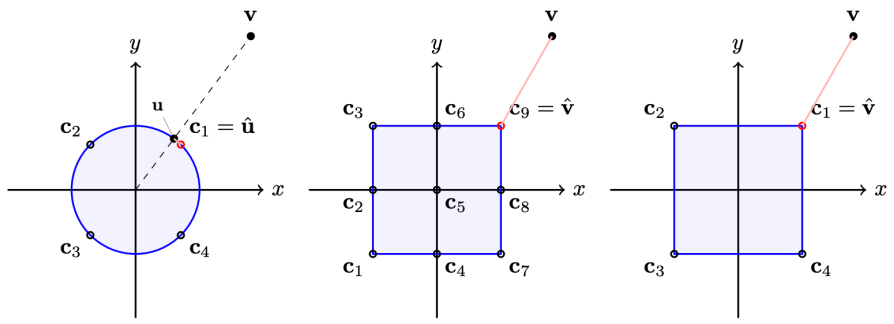

(a) BSQ (b) FSQ (c) LFQ

Figure 2: **Illustration of BSQ compared to LFQ and FSQ in the simplest case of $L = 2$.** In FSQ, we further consider each channel has 3 possible values $\{-1, 0, 1\}$. The Voronoi diagram for both FSQ and LFQ looks like hypercubes that partition the entire space while BSQ's looks like a hypersphere evenly divided by 2^L centroids.

claude-2-100k 的回答。。

- MAGVIT: Masked Generative Video Transformer：使用了 3D 向量量化 (3D VQ) 自动编码器来将视频量化为离散 token
  - 设视频 V 有 T 帧，其形状为 $T \times H \times W \times 3$。
  - 3D VQ 编码器 f_T 会把视频量化为一个 token 序列 z, 其中 $z \in Z^T$,Z 是码本,T 是 token 序列长度。
  - 3D VQ 解码器 f_T^{-1} 则可以从 latent token z 重构回视频像素。
- Genie: Generative Interactive Environments：使用了 2D 向量量化 (2D VQ) 方法
  - 每一帧图像 I 先通过一个 2D VQ 编码器 f 编码为一个 token 序列 z, 其中 $z \in Z^N$,Z 是 2D 码本。
  - 然后, 对时间序列上的 token $z_1, z_2, \ldots, z_T$ 应用一个 1D 卷积网络, 以捕获时间信息。
  - 再通过 2D VQ 解码器 f^{-1} 解码回每一帧图像。
- Vivit: A video vision transformer：使用 tubelet-embedding
  - 均匀地在时间轴上抽样 n_t 个帧, 然后把每帧处理成 $n_h \times n_w$ 个 patch, 最终把所有 patch 连接起来

2.4 SORA

OpenAI 首个 AI 视频模型炸裂登场，彻底端掉行业饭碗！60 秒一镜到底惊人，世界模型真来了?

https://openai.com/sora

https://openai.com/research/video-generation-models-as-world-simulators

一锤降维！解密 OpenAI 超级视频模型 Sora 技术报告，虚拟世界涌现了

Sora 爆火 48 小时：杨立昆揭秘论文，参数量或仅 30 亿

微软 37 页论文逆向工程 Sora，得到了哪些结论?

攻陷短视频后，Sora 将需要 72 万块 H100 GPU

Sora: A Review on Background, Technology, Limitations, and Opportunities of Large Vision Models

Sora 之后，OpenAI Lilian Weng 亲自撰文教你从头设计视频生成扩散模型

https://lilianweng.github.io/posts/2024-04-12-diffusion-video/

整体感觉:

- latent diffusion 的隐空间
- vit 和 swin transformer 的 patch

2.4.1 现有方法

现有的视频生成方法大多只能用于少数分类的视频、比较短的视频，或者固定长度的视频。

- recurrent networks
  - 2015 年的Unsupervised learning of video representations using lstms
  - 2017 年的Recurrent environment simulators
  - 2018 年的World models
- generative adversarial networks
  - 2016 年的Generating videos with scene dynamics
  - 2018 年的Mocogan: Decomposing motion and content for video generation
  - 2019 年的Adversarial video generation on complex datasets
  - 2022 年的Generating long videos of dynamic scenes
- autoregressive transformers
  - 2021 年的Videogpt: Video generation using vq-vae and transformers
  - 2022 年的Nüwa: Visual synthesis pre-training for neural visual world creation
- diffusion models
  - 2022 年的Imagen video: High definition video generation with diffusion models
  - 2023 年的Align your latents: High-resolution video synthesis with latent diffusion models

前两类太古老了，sora 把后面两个（autogressive transformers 和 diffusion models）结合在一起了，而且能同时处理不同时长、分辨率的视频和图像

2.4.2 将视频转成 spacetime latent patches

2.4.2.1 Vivit

Vivit: A video vision transformer

整体受 ViT 的启发

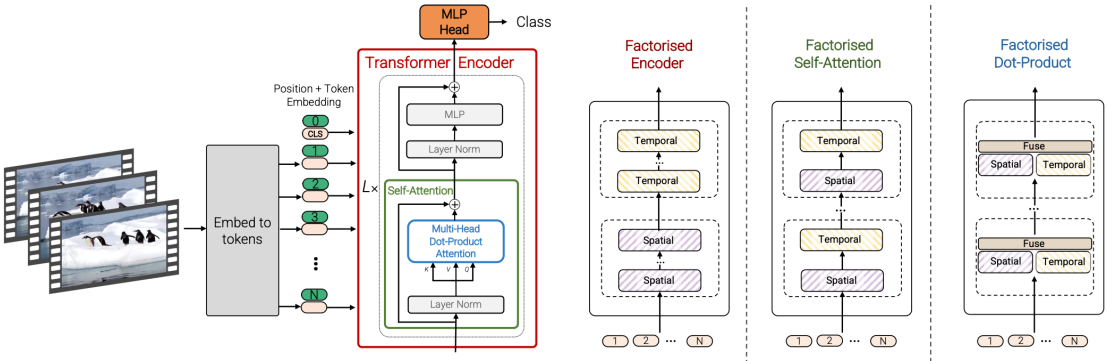

Figure 1: We propose a pure-transformer architecture for video classification, inspired by the recent success of such models for images [18]. To effectively process a large number of spatio-temporal tokens, we develop several model variants which factorise different components of the transformer encoder over the spatial- and temporal-dimensions. As shown on the right, these factorisations correspond to different attention patterns over space and time.

先分 patch，再分别过时间的 transformer（temporal transformer）和空间的 transformer（spatial transformer）

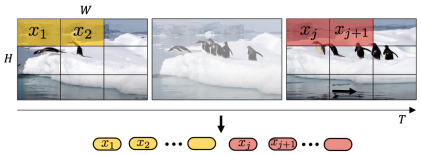

Figure 2: Uniform frame sampling: We simply sample n_t frames, and embed each 2D frame independently following ViT [18].

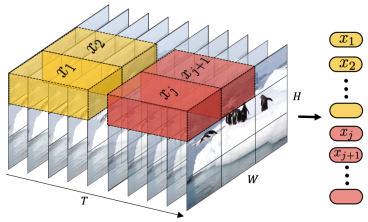

Figure 3: Tubelet embedding. We extract and linearly embed non-overlapping tubelets that span the spatio-temporal input volume.

具体的分 patch 方式如上图

2.4.2.2 latent 空间上的 patch

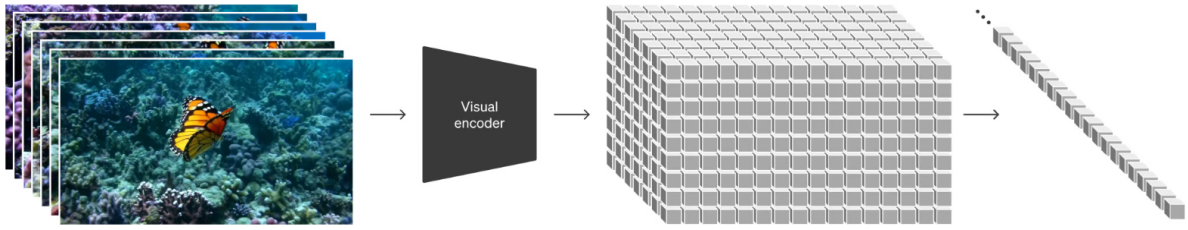

参考 stable-diffusion，即High-Resolution Image Synthesis with Latent Diffusion Models，把 patch 切分改成在 latent 空间上进行

- 将视频映射成**隐空间** (latent space) 的表示
- 把隐空间的表示切分成 **spacetime patches**

预估时，可以通过在一个合适大小的 grid 里排列随机初始化的 patches（we can control the size of generated videos by arranging randomly-initialized patches in an appropriately-sized grid.）来控制生成视频的大小。估计是参考了下面这篇：

论文参考了这个Patch n'Pack: NaViT, a Vision Transformer for any Aspect Ratio and Resolution，可以使下面提到的 DiT 适应各种分辨率/持续时间/宽高比。

2.4.3 Diffusion Transformer

Scalable diffusion models with transformers提出了 DiT，替换 stable diffusion 中的 u-net

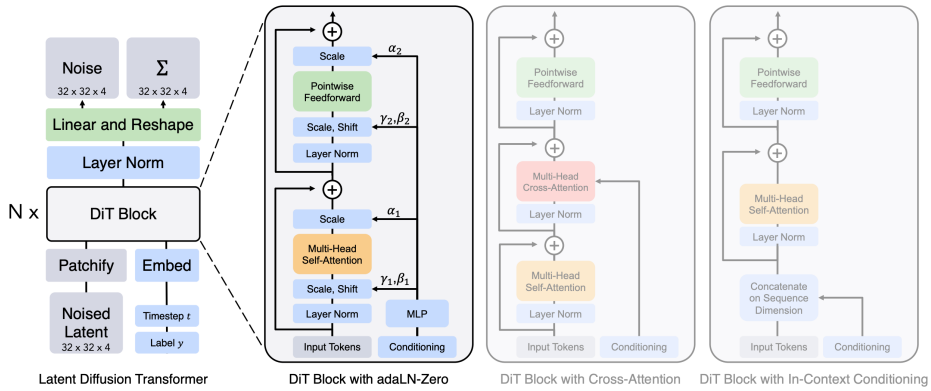

Figure 3. **The Diffusion Transformer (DiT) architecture.** *Left:* We train conditional latent DiT models. The input latent is decomposed into patches and processed by several DiT blocks. *Right:* Details of our DiT blocks. We experiment with variants of standard transformer blocks that incorporate conditioning via adaptive layer norm, cross-attention and extra input tokens. Adaptive layer norm works best.

DiT=VAE 编码器 + ViT + DDPM + VAE 解码器

sora 是一个扩散模型，输入加了噪声的 patches，还可以加上一些如 text prompt 的条件，预测原本『干净』的 patches。

之前的做法大多将视频全裁成相同长度和大小的，例如 4s 的 256×256，sora 可以直接用原始视频

2.4.4 语言理解

参考 DALL-E3 (Improving Image Generation with Better Captions)，训练了一个 highly descriptive 的视频描述生成器，拿这个生成器给训练集中的所有视频重新生成描述，再拿来训练。

此外，还用上了 GPT，将用户输入的短的 prompt 改写成更长更详细的视频描述用于生成。

2.4.5 使用图像/视频作为 prompt

- **图像转动画**：可以让静止的图像动起来
- **扩展视频**：可以对视频进行扩展（extend），在时间轴上向前或者向后进行延展（比如同样是一个石头落地，能生成 4 个视频，每个视频里的石头从不同的地方飞过来，落在同一个地面上）
- **编辑视频**：输入视频和一个文本 prompt，能够对视频进行编辑，例如把场景从沙漠替换成树林，类似Sdedit: Guided image synthesis and editing with stochastic differential equations
- **连接视频**：输入两个看似毫不相关的视频，能通过很自然的方式把这两个视频衔接在一起

2.4.6 生成图像

图像就是一帧的视频，可以通过在时间范围为一帧的空间 grid 中排列高斯噪声 patches（arranging patches of Gaussian noise in a spatial grid with a temporal extent of one frame）来生成图像，同样能生成不同分辨率的图像，最多 2048×2048

2.4.7 涌现的模拟能力

- **3D 一致性**：随着镜头的移动，视频中的人物或物体在 3d 空间中能在移动中保持一致
- **Long-range coherence and object permanence（远程连贯性和物体持久性）**：sora 能对短期和长期依赖关系进行建模，例如：
  - 可以保留人物体，即使它们被遮挡或离开当前帧。
  - 可以在单个样本中生成同一角色的多个镜头，并在整个视频中保持其外观的不变
- **与世界交互**：例如画家可以在画布上留下新的笔触，并随着时间的推移而持续存在，人吃东西能留下齿痕
- **模拟数字世界**：可以同时通过基本策略控制《我的世界》中的玩家，同时以高保真度渲染世界及其动态，只需要在 prompt 里提到“我的世界”的标题就可以实现。

2.4.8 存在的问题

- 不能准确地模拟许多基本相互作用的物理过程，例如玻璃破碎。
- 其他交互（例如吃食物）并不总是会产生对象状态的正确变化，例如长时间样本中出现的不连贯性或对象的自发出现。

2.5 open-sora（Colossal-AI）

没等来 OpenAI，等来了 Open-Sora 全面开源

Open-Sora 全面开源升级：支持 16s 视频生成和 720p 分辨率

2.5.1 模型架构

v1 版本：https://github.com/hpcaitech/Open-Sora/blob/main/docs/report_v1.md

v2 版本：https://github.com/hpcaitech/Open-Sora/blob/main/docs/report_02.md

2.5.1.1 VAE 部分

sora 用了 spatial-temporal VAE 来降低 temporal 的维度，但并没有开源且高质量的 spatial-temporal VAE：

- MAGVIT：的 $4 \times 4 \times 4$ 的 VAE 并没有开源
- VideoGPT：的 $2 \times 4 \times 4$ 的 VAE 在实验中效果不好

因此，使用https://huggingface.co/stabilityai/sd-vae-ft-mse-original的 2D VAE

对于 24fps 的 1min 视频，有 $24 \times 60 = 1440$ 帧，用 4 倍的 VAE 下采样和 2 倍的 patch size 下采样，有大约 $1440\times \approx 1.5M$ 的 token。对这些 token 算全部的 attention 的计算开销很大，所以参考Latte: Latent Diffusion Transformer for Video Generation(代码https://github.com/Vchitect/Latte) 的方案，使用 **spatial-temporal attention** 来减小计算量。

以下是 latte 的 4 个变种

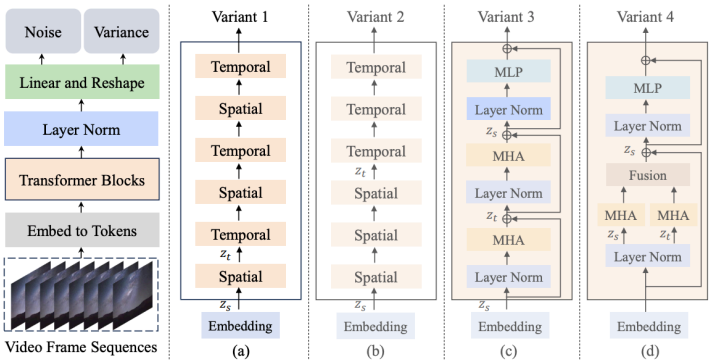

Fig. 2: The pipeline of Latte for video generation. Four model variants of Latte are proposed to efficiently capture spatio-temporal information in videos. Each block depicted in light orange represents a Transformer block. The standard Transformer blocks (described in Fig. 4b) are employed in (a) and (b). Meanwhile, (c) and (d) employ our respective Transformer block variants. For the sake of simplicity, encoding and decoding processes for VAE are not shown in the diagram.

STDiT(sequential) 和 latte 的变种 3 类似，STDiT(parallel) 和 latte 的变种 4 类似，在 $16 \times 256 \times 256$ 的视频上，发现效果如下，最终采用了 STDiT(sequential)。

$$DiT(full) > STDiT(Sequential) > STDiT(Parallel) \approx Latte$$

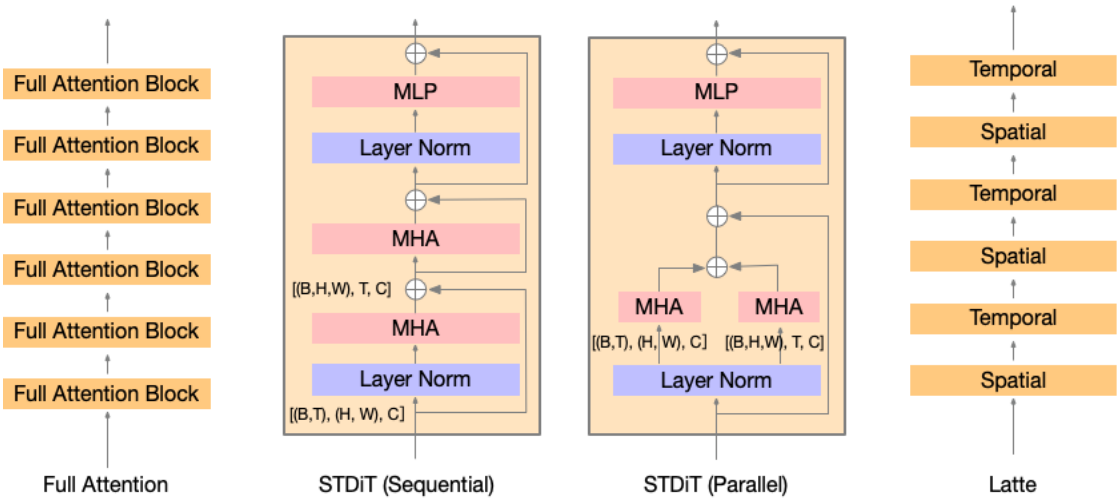

2.5.1.2 生成部分

PixArt-α: Fast Training of Diffusion Transformer for Photorealistic Text-to-Image Synthesis使用 **T5 作为条件的 DiT** 结构，能生成高质量的图像。用 PixArt-α 对模型初始化，并对**插入的 temperal attentioin** 用 0 初始化，能够让模型一开始就保留图片生成的能力。插入的 attention 让参数量从 580M 涨到了 724M。

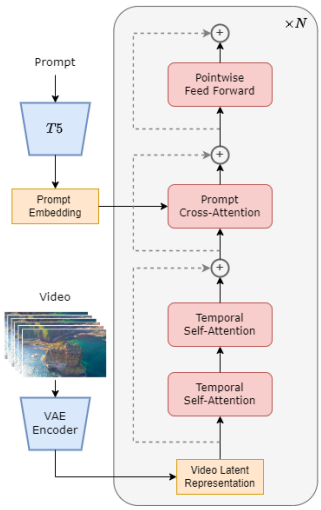

2.5.1.3 训练

参考 PixArt-α 和 Stable Video Diffusioin(Stable Video Diffusion: Scaling Latent Video Diffusion Models to Large Datasets)，采用了 progressive 的训练策略：

- 大规模图像预训练：前面提到的，直接使用https://huggingface.co/stabilityai/sd-vae-ft-mse-original的 2D VAE
- 大规模视频预训练：在质量相对差的 366K 的预训练数据集 (HD-VG-130M 数据集) 上训练 $16 \times 256 \times 256$，这里的 16 指的是 16 帧

- 高质量视频数据微调：在高质量的 20K 的数据集 (Pexels 数据集) 上训练 $16 \times 256 \times 256$、$16 \times 512 \times 512$ 和 $64 \times 512 \times 512$。

由于使用了 scaled position embedding，这个策略极大地减少了训练消耗。此外，对于 16 帧的训练，每 3 帧降采样一次，对于 64 帧的训练每 2 帧降采样一次。

数据标注方法：抽取 3 帧，然后设计 prompt，用 LLaVA 生成高质量的标题：

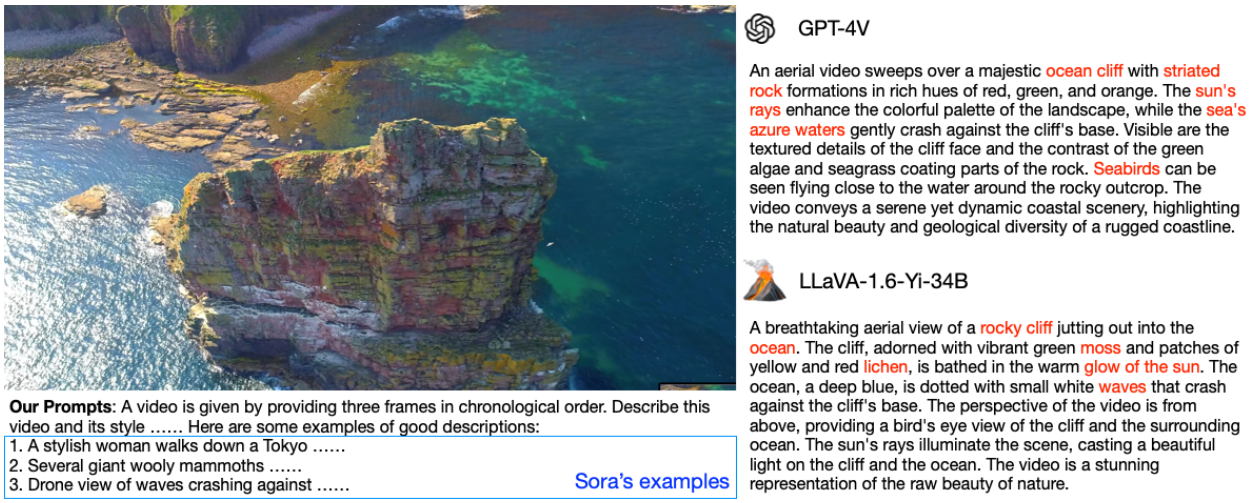

- 学习率：1e-4 太大了，改成了 2e-5
- **batchsize 比较大**的时候，**fp16 比 bf16 更不稳定**，而且可能导致生成错误，所以对于 $64 \times 512 \times 512$ 使用 **bf16**

提供了便捷的视频数据预处理脚本，可以轻松地在自己的数据集上快速生成训练所需的视频 / 文本对，包括公开视频数据集下载，长视频根据镜头连续性分割为短视频片段，使用开源 LLaVA 生成精细的提示词。

2.6 open-sora(北大版)

超 10 秒高分辨率，北大 Open Sora 视频生成更强了，还支持华为芯片

2.7 MORA

Sora 不开源，微软给你开源！全球最接近 Sora 视频模型诞生，12 秒生成效果逼真炸裂

复刻 Sora 的通用视频生成能力，开源多智能体框架 Mora 来了

Mora: Enabling Generalist Video Generation via A Multi-Agent Framework

2.8 minigpt4-video

AI 视频理解天花板，全新 MiniGPT4-Video 刷爆 SOTA！宝格丽宣传片配文一绝

2.9 mini-gemini

刷爆多模态任务榜单！贾佳亚团队 Mini-Gemini 登热榜，代码、模型、数据全部开源

模型地址：https://huggingface.co/collections/YanweiLi/mini-gemini-6603c50b9b43d044171d0854 数据地址：https://huggingface.co/collections/YanweiLi/mini-gemini-data-660463ea895a01d8f367624e

Mini-Gemini: Mining the Potential of Multi-modalityVision Language Models

VLM(vision lm) 虽然有很多，但和 gemini、gpt-4 等的差距还是比较大，作者认为主要原因是**高分辨率视觉标记不够、vision 推理数据质量不高。**

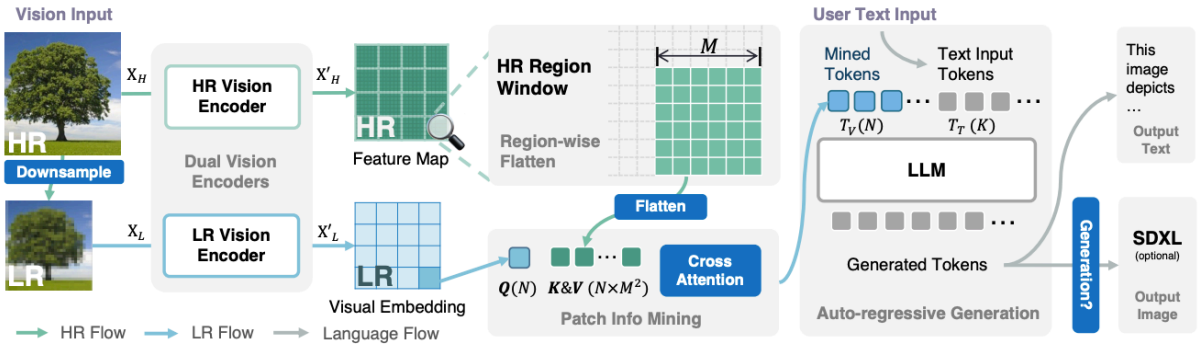

Figure 2: The framework of Mini-Gemini with any-to-any workflow.

作者利用**额外的视觉编码器**进行**高分辨率细化**，构建了一个高质量的数据集。构建了一个 Mini-Gemini 架构，支持一系列从 2B 到 34B 的密集和 MoE LLM，在 zero-shot 测试集上超过了私有模型。

https://github.com/dvlab-research/MiniGemini

2.10 Vidu

当前最强国产 Sora！清华团队突破 16 秒长视频，懂多镜头语言，会模拟物理规律

采用了和 Sora 完全一致的 Diffusion 和 Transformer 融合的架构，底层基于All are Worth Words: A ViT Backbone for Diffusion Models的 U-ViT 架构。

基于 U-ViT 架构，2023 年 3 月，团队在开源的大规模图文数据集 LAION-5B 上训练了 10 亿参数量的多模态模型 ——UniDiffuser，并将其开源（参见清华朱军团队开源首个基于 Transformer 的多模态扩散大模型，文图互生、改写全拿下）。

UniDiffuser 主要擅长图文任务，能支持图文模态间的任意生成和转换。UniDiffuser 的实现有一项重要的价值 —— 首次验证了融合架构在大规模训练任务中的可扩展性（Scaling Law），相当于将 U-ViT 架构在大规模训练任务中的所有环节流程都跑通。

这些在图文任务中积累的工程经验为视频模型的研发打下了基础。因为视频本质上是图像的流，相当于是图像在时间轴上做了一个扩增。因此，在图文任务上取得的成果往往能够在视频任务中得到复用。Sora 就是这么做的：它采用了 DALL-E 3 的重标注技术，通过为视觉训练数据生成详细的描述，使模型能够更加准确地遵循用户的文本指令生成视频。这种效应也必然会发生在「Vidu」上面。

根据此前的消息推测，「Vidu」也复用了生数科技在图文任务的很多经验，包括训练加速、并行化训练、低显存训练等等，从而快速跑通了训练流程。据悉，他们通过视频数据压缩技术降低输入数据的序列维度，同时采用自研的分布式训练框架，在保证计算精度的同时，通信效率提升 1 倍，显存开销降低 80%，训练速度累计提升 40 倍。

2.11 Vidu 1.5

视觉模型学会 LLM 独门秘籍「上下文记忆」，迎来智能涌现的大爆发！

2.12 gen-3

Runway 版 Sora 发布：高保真、超强一致性，Gen-3 Alpha 震撼到网友了

2.13 可灵

快手「可灵」爆火：海外 AI 圈巨震，中国版 Sora 一号难求

快手可灵凭什么频繁刷屏？揭秘背后三项重要研究

- 数据集：Koala-36M
  - A Large-scale Video Dataset Improving Consistency between Fine-grained Conditions and Video Content
  - https://github.com/KwaiVGI/Koala-36M

- 视频生成领域的 Scaling Law：Towards Precise Scaling Laws for Video Diffusion Transformers
- 通用世界模型：Owl-1: Omni World Model for Consistent Long Video Generation
  - https://github.com/huang-yh/Owl

2.14 V2A

杀疯了！谷歌卷视频到语音，逼真音效让 AI 视频告别无声！

https://deepmind.google/discover/blog/generating-audio-for-video/

2.15 长视频 LongVA

7B 最强长视频模型！LongVA 视频理解超千帧，霸榜多个榜单

Long Context Transfer from Language to Vision

2.16 LONGVILA

支持 1024 帧、准确率近 100%，英伟达「LongVILA」开始发力长视频

LONGVILA: SCALING LONG-CONTEXT VISUAL LANGUAGE MODELS FOR LONG VIDEOS

https://github.com/NVlabs/VILA/blob/main/LongVILA.md

2.17 liveportrait

快手开源 LivePortrait，GitHub 6.6K Star，实现表情姿态极速迁移

LivePortrait: Efficient Portrait Animation with Stitching and Retargeting Control

https://github.com/KwaiVGI/LivePortrait

2.18 diffusion forcing

无限生成视频，还能规划决策，扩散强制整合下一 token 预测与全序列扩散

Diffusion Forcing:Next-token Prediction Meets Full-Sequence Diffusion

https://github.com/buoyancy99/diffusion-forcing

2.19 VideoSys

视频生成要有自己的系统！尤洋团队历时半年开源 VideoSys

https://github.com/NUS-HPC-AI-Lab/VideoSys

2.19.1 Pyramid Attention Broadcast (PAB)

Real-Time Video Generation with Pyramid Attention Broadcast

https://github.com/NUS-HPC-AI-Lab/VideoSys/blob/master/docs/pab.md

2.19.2 Dyanmic Sequence Parallelism（DSP）

DSP: Dynamic Sequence Parallelism for Multi-Dimensional Transformers

https://github.com/NUS-HPC-AI-Lab/VideoSys/blob/master/docs/dsp.md

2.20 GameNGen

扩散模型做游戏引擎，单 TPU 20 FPS 模拟毁灭战士，谷歌最新 GameNGen 太博眼球了

2.21 Firefly

厉害了！Adobe 新出 Firefly 视频模型，2 分钟速成高清大片

https://blog.adobe.com/en/publish/2024/09/11/bringing-gen-ai-to-video-adobe-firefly-video-model-coming-soon

2.22 MovieGen

Meta 又给 OpenAI 一记重击，视频生成 Movie Gen 震撼登场，甚至可以配音、编辑

Meta 版 Sora 无预警来袭！抛弃扩散损失，音视频生成/画面编辑全包，92 页论文无保留公开

MovieGen: A Cast of Media Foundation Models

2.23 EMOVA

mini-GPT4o 来了？能看、能听、会说，还情感丰富的多模态全能助手 EMOVA

EMOVA: Empowering Language Models to See, Hear and Speak with Vivid Emotion

2.24 LLaVA-Video

突破视频多模态大模型瓶颈！「合成数据」立大功，项目已开源

VIDEO INSTRUCTION TUNING WITH SYNTHETIC DATA

2.25 Emu3

视频、图像、文本，只需基于下一个 Token 预测：智源 Emu3 发布，验证多模态模型新范式

https://github.com/baaivision/Emu3

Emu3: Next-Token Prediction is All You Need

https://huggingface.co/collections/BAAI/emu3-66f4e64f70850ff358a2e60f

2.26 hunyuan-video

腾讯版 Sora 发布即开源！130 亿参数，模型权重、推理代码全开放

HunyuanVideo: A Systematic Framework For Large Video Generative Models

https://github.com/Tencent/HunyuanVideo

2.27 STIV

(toread)

Sora 之后，苹果发布视频生成大模型 STIV，87 亿参数一统 T2V、TI2V 任务

STIV: Scalable Text and Image Conditioned Video Generation

2.28 Veo 2

谷歌版 Sora 升级 4K 高清！一句话控制镜头运动，跑分叫板可灵海螺

https://deepmind.google/technologies/veo/veo-2/

2.29 通义万相

通义万相视频生成重磅升级，成功登顶 VBench，运镜、质感直达专业级

https://tongyi.aliyun.com/wanxiang/

2.30 其他

扩散模型与文生视频

多模态大模型不够灵活，谷歌 DeepMind 创新架构 Zipper：分开训练再「压缩」

Zipper: A Multi-Tower Decoder Architecture for Fusing Modalities