

1 2023–2025 大语言模型赋能推荐系统的研究与实践综述

随着大语言模型（LLM）的崛起，学术界和工业界开始探索将其应用于推荐系统，以利用 LLM 强大的语言理解、知识和生成能力来提升推荐效果。本文系统梳理了 **2023 年至 2025 年 4 月** 期间，arXiv 上有关“大语言模型 + 推荐系统”的研究进展和落地实践，根据六大范式进行分类讨论，并列举每种范式下具有代表性的学术工作与工业应用案例。

1.1 1. Prompt 式推荐（零样本/小样本/提示排序）

1.1.1 1.1 方法背景与技术框架

Prompt 式推荐是指通过提示（prompt）引导预训练的大语言模型直接执行推荐任务。在这种范式中，我们不对 LLM 进行专门的训练，而是通过精心设计的提示，将用户偏好、历史行为和候选商品等信息以自然语言格式提供给 LLM，让其生成推荐结果。这一思路的核心在于利用 LLM 强大的零样本/小样本学习能力，让模型“即插即用”地充当推荐排序模型（[2305.08845] Large Language Models are Zero-Shot Rankers for Recommender Systems）（[2304.03153] Zero-Shot Next-Item Recommendation using Large Pretrained Language Models）。技术框架通常包括：将用户画像和上下文转换成提示模板，可能附加少量示例，然后让 LLM 推理输出用户可能感兴趣的项目或对候选项的偏好排序概率。Prompt 式推荐的优势在于无需针对推荐任务进行训练即可利用 LLM 丰富的世界知识和语言推理能力，实现冷启动场景下的推荐（[2304.03153] Zero-Shot Next-Item Recommendation using Large Pretrained Language Models）。同时，LLM 生成的推荐结果还天然带有解释性（因为 LLM 可以给出理由）。然而挑战也很明显：候选集合极大时的效率问题（LLM 对长列表评分的开销极高）以及提示设计的合理性（如何确保 LLM 理解用户历史行为顺序、不受提示中位置偏见影响等）（[2305.08845] Large Language Models are Zero-Shot Rankers for Recommender Systems）。因此，该范式的技术框架常辅以提示工程（优化 prompt 模板、加入链式思考等）和候选精排（先用传统模型筛选小规模候选，再交由 LLM 决策）等技术来提升效果和效率。

1.1.2 1.2 代表性研究工作

- **Large Language Models are Zero-Shot Rankers for Recommender Systems (2023)** ([2305.08845] Large Language Models are Zero-Shot Rankers for Recommender Systems): Yupeng Hou 等提出将推荐视为有条件的排序任务，通过精心设计 prompt 模板，将用户的序列历史行为作为条件，将待排序的物品作为候选列表嵌入提示，令 GPT-3/4 这类 LLM 直接输出评分来进行排序。结果表明，在零样本设置下，LLM 对推荐排序表现出有前景的能力，可逼近甚至挑战无训练的传统模型。他们还发现 LLM 提示排序存在易受位置和流行度偏见等问题，并通过特殊 prompt 和自举（bootstrapping）策略缓解偏差（[2305.08845] Large Language Models are Zero-Shot Rankers for Recommender Systems）。该工作代码已开源，验证了即使不针对推荐微调，LLM 也可作为强力排序器。（是否生成式：否，LLM 用于评分排序；是否使用 LLM 结构：是，直接调用 GPT 模型；代码开源：是）
- **Zero-Shot Next-Item Recommendation using Large PLMs (2023)** ([2304.03153] Zero-Shot Next-Item Recommendation using Large Pretrained Language Models): Lei Wang 和 Ee-Peng Lim 提出零样本下的大语言模型下一步推荐方法。他们设计了一个三阶段的 Prompt 方案“Next-Item Recommendation (NIR) Prompting”：首先利用外部模块根据用户历史筛选候选集合，然后提示 GPT-3 依次总结用户兴趣 -> 回顾代表性历史物品 -> 生成推荐列表（[2304.03153] Zero-Shot Next-Item Recommendation using Large Pretrained Language Models）。在 MovieLens 数据上，GPT-3 零样本推荐的命中率甚至超过了一些训练的深度序列模型（[2304.03153] Zero-Shot Next-Item Recommendation using Large Pretrained Language Models）。这证明了大模型强大的推理泛化能力。作者也开源了实现代码。（是否生成式：部分，是让 GPT-3 生成物品名称列表；是否使用 LLM 结构：是，调用 GPT-3 API；代码开源：是）
- **RecPrompt: News Recommendation via Self-tuning Prompting (2024)** ([2312.10463] RecPrompt: A Self-tuning Prompting Framework for News Recommendation Using Large Language Models): Dairui Liu 等研究了在新闻推荐中自动优化 prompt。提出 RecPrompt 框架，由一个新闻推荐模型和一个提示优化器组成，采用迭代自举的方法自动调整 Prompt。（[2312.10463] RecPrompt: A Self-tuning Prompting Framework for News Recommendation Using Large Language Models）实验使用 GPT-4 对 400 名真实用户进行新闻推荐，自适应地调整提示后，点击率等指标相比 SOTA 深度模型有显著提升（AUC 提升 3.36%，nDCG@5 提升 9.64% 等）（[2312.10463] RecPrompt: A Self-tuning Prompting Framework for News Recommendation Using Large Language Models）。此外引入 TopicScore 评估 LLM 总结用户兴趣主题的能力。RecPrompt 是首个将 Prompt 工程与推荐模型闭环结合的工作。（是否生成式：否，GPT-4 用于排序评分；是否使用 LLM 结构：是，调用 GPT-4 API；代码开源：未明确）
- **LLM-Rec: Prompting LLMs for Text-based Recommendation (2023)** ([2307.15780] LLM-Rec: Personalized Recommendation via Prompting Large Language Models): Hanjia Lyu 等聚焦文本内容推荐，利用 LLM 提升物品文本描述的表示质量。他们设计了四类 prompt 策略，让 GPT 生成更丰富的物品属性描述作为额外特征供一个简单的推荐模

型（如 MLP）使用。结果显示，经 LLM 扩充文本后，哪怕简单模型的效果也媲美甚至优于复杂的内容推荐模型 ([2307.15780] LLM-Rec: Personalized Recommendation via Prompting Large Language Models)。凸显了提示式输入增强在推荐中的价值。（是否生成式：否，LLM 生成辅助信息；是否使用 LLM 结构：是，调用 GPT 生成文本；代码开源：未明确）

（更多相关工作：例如 TALLRec (An Efficient All-round LLM-based Recommender System - arXiv) 使用小规模示例提示结合 LoRA 微调提升 LLM 推荐效果，PALR 提出个性化提示生成策略等。下文将在其他范式部分介绍。）

1.1.3 1.3 学术界成果与方法进展

在 Prompt 式推荐范式下，学术界近两年进行了大量探索，逐步揭示了 LLM 直接用于推荐的潜力与局限：

首先，一系列开创性工作验证了 LLM 零样本推荐的可行性。例如 Hou 等发现 GPT-3.5/4 在排序任务上具有惊人的零样本能力，只需将用户历史和候选项以适当格式嵌入提示，LLM 即可给出符合偏好的排序结果 ([2305.08845] Large Language Models are Zero-Shot Rankers for Recommender Systems)。Wang & Lim 的研究进一步证明，经过良好设计的提示，LLM 推荐性能甚至可超越训练有素的深度模型 ([2304.03153] Zero-Shot Next-Item Recommendation using Large Pretrained Language Models)。这些结果表明，大模型已经内隐学习到了与推荐相关的知识和推理能力，哪怕从未专门训练过推荐任务。

针对提示设计，学术界识别出一些关键挑战并提出对策。例如，LLM 在顺序推荐中可能忽视交互顺序，对提示中最近的物品给予过高权重，或者受热门物品词频影响而产生偏置 ([2305.08845] Large Language Models are Zero-Shot Rankers for Recommender Systems)。为此，研究者提出在提示中显式标注时间顺序，或加入例如“不要仅根据流行度推荐”等指令，来纠正 LLM 的认知偏差 ([2305.08845] Large Language Models are Zero-Shot Rankers for Recommender Systems)。还有工作引入 Chain-of-Thought 等技巧，引导模型逐步分析用户兴趣再给结论，提升推荐准确性和多样性。

另外，为了解决候选集合过大的问题，不少研究采用了两阶段策略：先用轻量模型进行召回或粗排，选出 top-N 候选，再让 LLM 在较小集合上精排。例如 Zero-Shot NIR 方法就借助外部模块筛选电影候选，再让 GPT-3 在 10 部候选中输出排名 ([2304.03153] Zero-Shot Next-Item Recommendation using Large Pretrained Language Models)。这样既降低了 LLM 推理负担，又减少了 LLM 可能“凭空”生成无关项的风险。

自适应的 Prompt 优化也是进展热点。RecPrompt 工作展示了自动 Prompt 调整可以进一步提升效果 ([2312.10463] RecPrompt: A Self-tuning Prompting Framework for News Recommendation Using Large Language Models)。不像人工提示，RecPrompt 用反馈不断修正提示内容，使 LLM 更关注用户兴趣未被满足的部分，从而在几个自举回合后取得显著性能增益。这种人机协同优化理念为 Prompt 式推荐打开了新思路。

总体而言，学术研究已经证实 LLM 可以作为零样本推荐模型使用，在冷启动场景下表现出色，同时为应对其局限开发了多种 prompt 工程策略和辅助机制。在这些工作的推动下，Prompt 式推荐正逐渐从实验走向更实际的问题规模，为工业界探索打下基础。

1.1.4 1.4 工业界落地案例

在工业界，对 Prompt 式推荐的尝试也已经开始出现，一些大型互联网公司利用 LLM 的通用能力来简化推荐系统架构或改进冷启动表现：

- **LinkedIn（领英）—“360Brew”通用排序模型：** ([2501.16450] 360Brew : A Decoder-only Foundation Model for Personalized Ranking and Recommendation) 领英团队在 2024 年提出了名为 360Brew 的超大规模基础模型（1500 亿参数）用于个性化推荐和排序任务 ([2501.16450] 360Brew : A Decoder-only Foundation Model for Personalized Ranking and Recommendation)。360Brew 采用文本接口，将用户行为和候选内容全部“verbalize”成文本提示输入单一的 Decoder-only LLM。一方面，一个模型即可统一处理领英站内 30 多个推荐与排序任务，实现了多任务一体化 ([2501.16450] 360Brew : A Decoder-only Foundation Model for Personalized Ranking and Recommendation)；另一方面，由于利用了 LLM 的推理和知识泛化能力，该模型在无额外微调的前提下对新领域任务表现出零样本适应性 ([2501.16450] 360Brew : A Decoder-only Foundation Model for Personalized Ranking and Recommendation)。离线实验显示，360Brew 在多个子任务上达到或超过了原有专门模型的性能 ([2501.16450] 360Brew : A Decoder-only Foundation Model for Personalized Ranking and Recommendation)。这一工业级案例表明，通过精心设计 Prompt 接口和训练流程，大模型有潜力替代传统繁杂的推荐系统流水线。（场景：职场社交 Feed、求职推荐等多场景；融合方式：全 Prompt 输入；是否生成式：否，生成得分排序；是否复用 LLM 结构：是，自研大模型；A/B 测试：尚在预生产，离线指标已与生产持平 ([2501.16450] 360Brew : A Decoder-only Foundation Model for Personalized Ranking and Recommendation)）
- **华为 Noah’s Ark Lab —LLMTreeRec 冷启动推荐：** (LLMTreeRec: Unleashing the Power of Large Language Models for Cold-Start Recommendations) (LLMTreeRec: Unleashing the Power of Large Language Models for Cold-Start Recommendations) 面对真实应用中新品/新用户缺乏交互数据的冷启动问题，华为提出并部署了 LLMTreeRec 框架 (LLMTreeRec: Unleashing the Power of Large Language Models for Cold-Start Recommendations)。其核心

思想是将海量候选物品组织成多叉树结构，通过多轮 Prompt 引导 LLM 逐层筛选：每一层 LLM 根据用户偏好选择下一层的分支，逐步缩小候选集合，最终定位最符合用户兴趣的物品 (LLMTreeRec: Unleashing the Power of Large Language Models for Cold-Start Recommendations)。这种树型检索大大提高了 LLM 决策的效率，使之可应用于上百万规模的候选集。离线结果表明，在系统冷启动场景下该方法效果达到 SOTA 水平，甚至接近有充足训练数据的深度模型 (LLMTreeRec: Unleashing the Power of Large Language Models for Cold-Start Recommendations)。更重要的是，LLMTreeRec 已经在华为某工业推荐系统中上线，并通过了在线 A/B 测试验证了优于既有模型的性能 (LLMTreeRec: Unleashing the Power of Large Language Models for Cold-Start Recommendations)。这是 Prompt 式 LLM 直接用于工业推荐决策的成功案例之一。(推荐场景：新用户商品推荐；融合方式：Prompt 引导逐层筛选树结构候选；是否生成式：否，生成下一步选择；是否复用 LLM 结构：是，调用开创性 LLM；A/B 测试：线上点击率优于基线模型 (LLMTreeRec: Unleashing the Power of Large Language Models for Cold-Start Recommendations))

(除上述案例外，一些公司也开始探索让内部通用大模型通过提示来执行推荐任务。例如，有报道指淘宝等电商在开发类似 ChatGPT 的购物助手，通过对话为用户推荐商品；又如 B 站据传尝试用大模型对冷门内容做长尾推荐。这些实践大多处于试验阶段，公开的细节和指标有限，因此未在此详述。)

1.2 2. 特征与语义增强（内容理解、冷启动、知识注入）

1.2.1 2.1 方法背景与技术框架

特征与语义增强范式侧重于利用 LLM 丰富的语义理解能力来改进推荐系统的输入特征表示和知识获取。传统的推荐系统很大程度上依赖 ID 嵌入和稀疏的历史行为，这往往忽略了物品内容和上下文中的大量语义信息 ([2405.03988] LEARN: Knowledge Adaptation from Large Language Model to Recommendation for Practical Industrial Application)。例如，一本书的文本描述、商品的属性和评论、用户发表的文本动态，这些都蕴含着潜在的偏好线索。但以往模型难以充分利用这些非结构化文本信息。LLM 作为在海量语料上训练的模型，具备出色的自然语言理解和常识推理能力，因而被用于提升推荐系统对内容和语义的感知：一是生成更优的特征表示，如用 GPT 对商品描述做摘要提炼关键信息，缓解冷启动物品缺少历史互动的问题；二是引入外部知识，例如利用 LLM 从知识图谱或百科中抽取知识点，增强推荐的多样性和准确性；三是判别噪声与真假，利用 LLM 识别评论的真假、标签的相关性，从而清洗训练数据等。

在技术框架上，这一范式通常通过两种途径融入 LLM：其一，LLM 作为特征提取器，即冻结预训练 LLM，用其编码物品描述、用户评论等文本，得到高质量的向量表示，与用户 IDEmbedding 结合输入推荐模型 ([2405.03988] LEARN: Knowledge Adaptation from Large Language Model to Recommendation for Practical Industrial Application)；其二，LLM 作为知识发现工具，通过 prompt 引导 LLM 去推理物品关联关系（如“买了 A 是否也可能买 B”），将推理得到的新特征（例如 A 和 B 的互补关系）注入推荐模型的数据管道。总体而言，特征与语义增强范式将 LLM 视为现有推荐系统的“外挂大脑”，帮助传统模型看懂看透以前看不懂的内容，从而提升对用户兴趣的刻画，特别在冷启动和长尾内容场景下改善推荐质量。

1.2.2 2.2 代表性研究工作

- **LLM-Rec: 利用 LLM 丰富物品文本描述 (2023)** ([2307.15780] LLM-Rec: Personalized Recommendation via Prompting Large Language Models)：该工作在第 1 节已提及，由于属于特征增强范式，这里归类说明。Lyu 等提出用 GPT 模型生成包含常识和细节的物品文本。例如对一个电影，提示 GPT 列出其主要情节、风格、类似影片等关键词，得到扩充描述，再将其作为额外特征并入推荐模型训练。实验发现，经 LLM 扩充后的文本特征大幅提高了推荐效果：在电影、商品等数据集上，一个简单的 MLP 模型使用增强文本即可超越复杂的内容推荐模型 ([2307.15780] LLM-Rec: Personalized Recommendation via Prompting Large Language Models)。这证明了 LLM 生成的语义特征能有效弥补原始描述的信息不足。(是否生成式：否，LLM 生成中间特征；是否复用 LLM 结构：是（推理生成特征时调用）；代码开源：未明确)
- **LEARN: 冻结 LLM 作为工业推荐的知识塔 (2024)** ([2405.03988] LEARN: Knowledge Adaptation from Large Language Model to Recommendation for Practical Industrial Application)：Jian Jia 等提出了一个面向工业应用的知识适配框架 LEARN ([2405.03988] LEARN: Knowledge Adaptation from Large Language Model to Recommendation for Practical Industrial Application)。他们将预训练 LLM（如 GPT 系列）的参数冻结，仅将其作为物品文本内容的编码器，以保持 LLM 对开放领域知识的记忆 ([2405.03988] LEARN: Knowledge Adaptation from Large Language Model to Recommendation for Practical Industrial Application)。同时设计一个协同过滤塔（IDEmbedding 塔），通过双塔结构融合 LLM 的“开世界”语义知识与传统“封闭世界”协同知识。在大规模工业数据集上，LEARN 相比纯 ID 模型有明显性能提升，并在六个 Amazon 商品评论数据集取得 SOTA ([2405.03988] LEARN: Knowledge Adaptation from Large Language Model to Recommendation for Practical Industrial Application)。更重要的是，作者报告了在真实线上业务上的 A/B 测试成功，表明该语义增强策略在工业环境中切实可行 ([2405.03988] LEARN: Knowledge Adaptation from Large Language Model to Recommendation for Practical Industrial Application)。他们也公开了代码以促进后续研究。(是否生成式：否，将 LLM 用作编码器；是否复用 LLM 结构：是（参数冻结使用）；代码开源：是)

- **Breaking the Barrier:** 利用知识推理提升工业推荐 (2024) ([Breaking the Barrier: Utilizing Large Language Models for Industrial Recommendation Systems through an Inferential Knowledge Graph](#)) ([Breaking the Barrier: Utilizing Large Language Models for Industrial Recommendation Systems through an Inferential Knowledge Graph](#)): 这是一篇由蚂蚁集团提出的工业报告。作者关注电商推荐中的互补品推荐 (买了 A 后推荐 B)。传统模型难以捕捉面包和牛奶这种常识性的互补关系, 该工作引入 Claude 2 LLM, 通过 Prompt 提供成对商品, 让 LLM 判断二者是否存在互补购买关系, 并给出理由 ([Breaking the Barrier: Utilizing Large Language Models for Industrial Recommendation Systems through an Inferential Knowledge Graph](#)) ([Breaking the Barrier: Utilizing Large Language Models for Industrial Recommendation Systems through an Inferential Knowledge Graph](#))。他们将 LLM 输出的判断结果构建为“互补知识图”, 纳入推荐系统的召回和排序特征中。在线实验在支付宝的优惠券和商品推荐场景中进行: 随机 10% 用户流量的对照试验显示, 引入 LLM 推理知识的方案 (LLM-KERec) 相比原系统点击和转化率显著提升, 如优惠券兑换量提升 6.24% 和 10.07%, 商品 GMV 提升 6.45% ([Breaking the Barrier: Utilizing Large Language Models for Industrial Recommendation Systems through an Inferential Knowledge Graph](#))。这种方法无需额外数据就让推荐系统具备了常识推理能力, 是 LLM 知识注入在工业界的成功应用。(推荐场景: 支付宝优惠券和商品推荐; 融合方式: LLM 推理互补关系形成知识图特征; 是否生成式: 部分, 生成 “Yes/No” 判断及解释; 是否复用 LLM 结构: 是, 调用 Claude API; A/B 测试: 转化提升 6~10% ([Breaking the Barrier: Utilizing Large Language Models for Industrial Recommendation Systems through an Inferential Knowledge Graph](#)))
- **FilterLLM:** 文本到用户分布的冷启动推荐 (2025) ([FilterLLM: Text-To-Distribution LLM for Billion-Scale Cold-Start Recommendation](#)): 阿里巴巴团队提出利用 LLM 解决海量新物品的冷启动分发问题。他们训练了一个名为 FilterLLM 的模型: 在 LLM 的输出空间扩展加入大量用户 ID 的专属 token, 并设计提示仅输入物品内容文本, 促使 LLM 直接输出一个用户 ID 分布 (即预测哪些用户可能喜欢该新物品) ([FilterLLM: Text-To-Distribution LLM for Billion-Scale Cold-Start Recommendation](#)) ([FilterLLM: Text-To-Distribution LLM for Billion-Scale Cold-Start Recommendation](#))。为高效训练如此海量的新 token, 他们使用协同过滤的嵌入初始化技巧, 结合对比学习来适配 LLM ([FilterLLM: Text-To-Distribution LLM for Billion-Scale Cold-Start Recommendation](#)) ([FilterLLM: Text-To-Distribution LLM for Billion-Scale Cold-Start Recommendation](#))。在线 A/B 测试进行了两个月, 覆盖日均 3 亿 PV 的推荐场景。结果显示, FilterLLM 相比之前的冷启动模型在召回速度上提升一个数量级, 同时冷启动推荐效果也有提升 ([FilterLLM: Text-To-Distribution LLM for Billion-Scale Cold-Start Recommendation](#))。这证明了 LLM 可以直接输出推荐所需的用户分布, 大幅加速新内容触达用户的效率。(推荐场景: 电商新商品冷启动; 融合方式: 扩展 LLM 词表表示用户, 输入物品文本输出用户 ID 概率分布; 是否生成式: 是, 生成用户列表; 是否复用 LLM 结构: 是 (微调 LLM 加新词); A/B 测试: 线上速度提高数量级且效果提升 ([FilterLLM: Text-To-Distribution LLM for Billion-Scale Cold-Start Recommendation](#)))

(其他相关工作: 如 ONCE ([Large Language Model Enhanced Recommender Systems: Taxonomy, Trend, Application and Future](#)) 首先尝试让 LLM 生成用户可能点击的新闻作为数据增强; LLM-EKF 提出用 LLM 填充知识图谱中的缺失边以改进推荐召回; LARR 通过 LLM 理解实时场景文本来辅助短视频推荐等等。)

1.2.3 2.3 学术界成果与方法进展

在特征与语义增强方面, 学术界的研究丰富了推荐系统对内容和知识的利用, 主要进展包括:

- 1) **内容理解与表征迁移:** 多项研究成功将预训练 LLM 用作强大的文本编码器嵌入到推荐模型中。例如, LEARN 框架通过双塔网络将冻结的 LLM 文本编码与可训练的 ID 嵌入结合, 显著提升了推荐性能 ([\[2405.03988\] LEARN: Knowledge Adaptation from Large Language Model to Recommendation for Practical Industrial Application](#))。又如 CoLLM 等工作尝试将协同过滤产生的 embedding 直接融合进 LLM 的隐层, 使 LLM 同时学习文本和协同信号 ([Large Language Models Are Universal Recommendation Learners](#))。总体来看, 这类方法证明了预训练语言模型的知识可以迁移到推荐领域, 只需很少甚至不需要调整参数, 就能提供比传统方法更通用、更语义丰富的表示, 从而改善冷启动和跨领域场景下的效果。
- 2) **知识注入与推理增强:** 针对推荐系统面临的知识瓶颈 (如互补关系、因果关系), 研究者利用 LLM 的推理能力引入外部知识源。蚂蚁金服的工作展示了让 LLM 充当“知识判别器”, 自动挖掘商品之间的语义关系能够极大拓展推荐系统的视野 ([Breaking the Barrier: Utilizing Large Language Models for Industrial Recommendation Systems through an Inferential Knowledge Graph](#)) ([Breaking the Barrier: Utilizing Large Language Models for Industrial Recommendation Systems through an Inferential Knowledge Graph](#))。还有学者利用 LLM 读取商品的维基百科信息, 提取属性标签补充到物品特征中, 或让 LLM 根据剧情简介推测用户对影片细分元素 (演员、主题) 的喜好, 以增强个性化。实验普遍表明, 补入这些 LLM 获取的知识后, 推荐的准确率和多样性都有所提高, 尤其在长尾物品 (历史数据稀少) 上效果提升更明显。
- 3) **软硬件权衡与高效部署:** 为了使 LLM 的语义增强能力在工业规模可用, 学术界也在探索更高效的集成方案。冻结 LLM 参数是一种思路, 可避免大模型在训练中“灾难性遗忘”其预训练知识 ([\[2405.03988\] LEARN: Knowledge Adaptation from Large Language Model to Recommendation for Practical Industrial Application](#))。此外, 一些方法通过知识蒸馏, 将 LLM 提取的内容特征用小模

型来近似，从而减少在线依赖。还有研究考虑将 LLM 放在推荐系统的上游离线阶段，用于数据增强或清洗——例如 Liu 等让 LLM 识别序列互动数据中的噪声并剔除 ([Large Language Model Enhanced Recommender Systems: Taxonomy, Trend, Application and Future](#))——这种方式也能降低实时开销。在学术界的努力下，LLM 增强推荐正朝着低成本、高收益的方向发展。

总的来说，语义增强范式的研究充分证明：LLM 可以赋予推荐系统“洞察力”和“常识”，不仅提升了推荐质量，也拓展了推荐系统可用的信息源，使其能够整合包括文本、知识图谱、跨域信息在内的多模态线索。

1.2.4 2.4 工业界落地案例

工业界对 LLM 进行特征与语义增强的落地已有一些成功报道，说明这一范式在大规模应用中具有现实价值：

- **阿里巴巴：商品互补推荐中的知识推理** -前文提及的蚂蚁集团案例 ([Breaking the Barrier: Utilizing Large Language Models for Industrial Recommendation Systems through an Inferential Knowledge Graph](#)) 展示了 LLM 推理互补知识在电商业务中的价值。他们以极小的代价（仅调用 LLM 推理判断）显著提升了三大实际场景的核心指标 ([Breaking the Barrier: Utilizing Large Language Models for Industrial Recommendation Systems through an Inferential Knowledge Graph](#))。该案例的成功在业界引起关注，证明利用 LLM 获取常识性知识可以破解长尾商品推荐难题，提升用户体验。目前，该方案已在支付宝的“超级福利”、支付结果页等场景上线部署。
- **某头部短视频平台：语义双塔匹配** -LEARN 框架的作者来自业界（字节跳动/Kuaishou 等可能背景），其在投稿中明确指出该方案经过了真实工业数据集和在线测试 ([\[2405.03988\] LEARN: Knowledge Adaptation from Large Language Model to Recommendation for Practical Industrial Application](#))。虽然具体公司未指明，但从作者包含某互联网公司研究员且提及“工业应用”，我们推测 LEARN 或类似的 LLM+ 双塔模型已经在短视频推荐或电商推荐中试验部署，通过对商品文本、视频描述等内容建模，提升了推荐召回的泛化能力。据论文描述，在线 A/B 测试结果验证了语义增强带来的效果增益 ([\[2405.03988\] LEARN: Knowledge Adaptation from Large Language Model to Recommendation for Practical Industrial Application](#))。这表明工业界开始接受“冻结 LLM 当特征提取”这种新范式，将其视为改进大型推荐系统的一种可行且低风险的插件。
- **阿里巴巴：冷启动用户分发加速** -FilterLLM 的方法已经在阿里内部进行了长周期的大流量测试 ([FilterLLM: Text-To-Distribution LLM for Billion-Scale Cold-Start Recommendation](#))。在内容生态非常丰富的平台（如淘宝、优酷）中，新内容如何高效触达潜在喜好用户一直是难题。FilterLLM 通过让 LLM “一步到位”地给出新内容的目标用户列表，把过去需要多轮召回排序的流程大大简化。据报道，两个月的线上实验中，不仅新内容曝光速度提升了一个量级，用户的点击和停留等表现也优于对照组 ([FilterLLM: Text-To-Distribution LLM for Billion-Scale Cold-Start Recommendation](#))。据悉，阿里已在考虑将该方案用于实际业务中，以增强新商品、新视频的分发效率。

总之，工业界对特征与语义增强范式的实践表明：**LLM 可以作为提升推荐系统效果的“催化剂”，在不推翻原有架构的情况下，通过丰富特征和知识，取得令人瞩目的收益。**随着更多公司验证 LLM 在内容理解和知识注入上的价值，可以预见这一范式将得到更广泛的应用。

1.3 3. 网络结构融合与参数高效微调（如 LoRA, MoE, Prompt Tuning 等）

1.3.1 3.1 方法背景与技术框架

尽管直接使用 LLM 进行推荐（Prompt 范式）和将 LLM 当工具辅助推荐（特征增强）都取得了成功，但还有一种思路是更紧密地融合 LLM 与推荐模型的网络结构，通过参数微调来让 LLM 更好地适配推荐任务。这一范式的出发点在于：预训练 LLM 并非专为推荐而生，其输出和训练目标与推荐目标存在差异。如果能在不牺牲 LLM 通用能力的前提下，对其进行适度微调，让模型更“懂”用户与物品的匹配关系，那么推荐性能有望进一步提升。然而，直接 Fine-tune 整个 LLM 代价高昂且可能过拟合小数据。为此，学术界引入了 NLP 领域成熟的参数高效微调（PEFT）技术，如 LoRA（低秩适配）([An Efficient All-round LLM-based Recommender System - arXiv](#))、Prefix/Prompt Tuning、Adapter 等，将少量新参数插入或融合到 LLM 中，利用极低的开销来调整模型行为。这类方法通过冻结大部分 LLM 参数，仅训练小规模参数模块，既保持了 LLM 强大的语言知识，又学到了推荐领域的新模式。

网络结构融合方面，也有工作尝试结合协同过滤结构与 LLM。例如，在 LLM 输出层接入一个用于生成推荐得分的专用头，或者增加一层用于处理 ID Embedding 的 MoE 专家网络，从而融合显式 ID 信号与 LLM 隐式语义。在技术框架上，这类范式通常需要一定程度的模型训练：要么是在已有 LLM 上附加新结构并训练（可能需要大规模交互数据做微调），要么是预训练时就考虑推荐任务目标（如通过多任务学习预训练一个同时具备语言和推荐能力的基础模型）。

简单来说，网络结构融合与高效微调范式追求“ $1 + 1 > 2$ ”的效果：将 LLM 的语言天赋和传统模型的协同效应合二为一，通过小幅训练调整，让 LLM 成为更专业的推荐模型，同时保留其生成解释等额外能力。

1.3.2 3.2 代表性研究工作

- **TALLRec: 基于 LoRA 的高效微调框架 (RecSys 2023) (An Efficient All-round LLM-based Recommender System - arXiv)**: Bao 等提出“TALLRec”，旨在高效地对齐 LLM 与推荐任务。他们采用 LoRA 方法对一个预训练语言模型的部分参数进行低秩适配微调，只训练不到 1% 的参数量，却成功让 LLM 学会了序列推荐的模式 (An Efficient All-round LLM-based Recommender System - arXiv)。实验在 MovieLens 等数据集上表明，TALLRec 在推荐准确率上优于不经微调直接用 LLM 的方法，也接近传统深度模型的水平，但训练成本大幅降低 (An Efficient All-round LLM-based Recommender System - arXiv)。这一工作验证了 PEFT 技术在推荐领域的可行性。(是否生成式：否，微调后模型用于预测评分；是否复用 LLM 结构：是 (LoRA 微调 GPT)；代码开源：是)
- **CoLLM: 协同 Embedding 融合 LLM (2023) (GitHub - nancheng58/Awesome-LLM4RS-Papers: Large Language Model-enhanced Recommender System Papers)**: 该工作探索将协同过滤的嵌入直接融合进 LLM。作者将预训练好的用户和物品 ID embedding 引入 LLM 的隐藏层，使模型在生成下一词时同时考虑这些 embedding 的影响。这样 LLM 既保留语言模型对文本的理解，又能利用用户-物品交互的协同信号。实验表明，这种融合提高了推荐准确率。(是否生成式：否；是否复用 LLM 结构：是 (融合结构)；代码开源：未明确)
- **Lifelong Personalized LoRA (2024)**: 针对推荐场景动态变化，Chen 等提出让每个用户拥有一组 LoRA 参数，对 LLM 进行个性化微调并能持续更新 (GitHub - nancheng58/Awesome-LLM4RS-Papers: Large Language Model-enhanced Recommender System Papers)。这种架构相当于为 LLM 加装用户记忆模块，随着用户行为新增，不断调整小规模参数，实现终身学习，避免模型过时。离线评估显示对长期用户偏好捕获更准确。(是否生成式：否；是否复用 LLM 结构：是 (多个 LoRA 模块)；代码开源：未明确)
- **Large Language Models meet Collaborative Filtering (KDD 2024)**: Wang 等提出一套“全能型”LLM 推荐系统，他们在一个基础 LLM 上同时融入了用户和物品的多个交互视图，构建统一模型处理评分预测、点击率预估等任务 (GitHub - nancheng58/Awesome-LLM4RS-Papers: Large Language Model-enhanced Recommender System Papers)。模型采用高效微调和蒸馏结合，使其在推荐数据上表现突出。(是否生成式：否；是否复用 LLM 结构：是；代码开源：未明确)

(其他相关工作：如 *Prompt Tuning* 用于提取用户评论中的偏好要素、*HLLM* 结构用于层次化地分解推荐意图、*E4SRec* 提出端到端的 LLM 序列推荐方案等。)

1.3.3 3.3 学术界成果与方法进展

网络结构融合与参数微调范式的研究丰富了将 LLM 改造为推荐模型的思路，主要进展体现在以下几方面：

1) 参数高效微调显著提升效果：多项研究证明，仅需很小的训练代价即可让 LLM 的推荐性能飞跃式提高。TALLRec 的实验结果表明，通过 LoRA 微调，LLM 对交互序列的建模能力明显增强，在 Hit 率等指标上大幅超越零样本 LLM (An Efficient All-round LLM-based Recommender System - arXiv)。这说明预训练 LLM 中蕴含的很多知识可以被微调唤醒来服务推荐任务，而 PEFT 方法提供了一个经济高效的途径。相比微调整个模型，LoRA 等方法不但计算开销低，也降低了过拟合风险，许多研究都报告 PEFT 微调后的 LLM 在小数据集上依然具有良好泛化。

2) 融合 ID 信号，弥补 LLM 短板：纯粹的 LLM 对 ID 这种稀疏符号并不敏感，学术界尝试将 ID 信息融入 LLM 架构。One 侧面是增加 **Embedding 融合层**：例如在 LLM 输入末尾附加用户 ID 特殊 token，使模型在生成推荐结果时受到该用户 embedding 的影响 (Large Language Models Are Universal Recommendation Learners)；或者采用多头输出结构，同时输出用户表示和语言序列，从而兼顾推荐精度和文本生成 (Large Language Models Are Universal Recommendation Learners)。这些融合策略有效地将协同过滤的精准度优势与 LLM 的广博知识结合起来 (Large Language Models Are Universal Recommendation Learners)。另一个侧面是**设计专用输出头**：一些工作在 LLM 顶层添加了一个评分预测头，用于直接输出 user-item 匹配分。这等于在 LLM 之上加了一层推荐模型，使训练能以推荐任务的损失为目标来更新部分参数。实践证明，这种在 LLM 基础上“加一层”的做法，能够引导 LLM 内部表征朝着对推荐更有利的方向调整，而不会破坏原有语言能力 (Large Language Models Are Universal Recommendation Learners)。

3) 持续学习与自适应：推荐系统需要随着时间推移更新。传统模型需频繁训练更新权重，而 LLM 若每次全模型调优显然不切实际。为此，有研究者探索 LLM 的持续学习机制，例如引入可反复训练的小模块来吸收新数据影响。前述个性化 LoRA 就是典型，它通过分用户维护小规模参数，实现了**按需的局部更新**，既保持大模型主干不变，又让模型逐步积累新知识。这与强化学习或元学习思想结合，涌现出如“根据反馈动态调整 Prompt/参数”的方法，使 LLM 推荐模型具备一定的自我改进能力。

总体来看，学术界在该范式的探索证明了：通过巧妙的结构改造和有限的参数训练，LLM 可以成为性能强大的推荐模型，并且能够弥补传统模型和 LLM 各自的不足。网络融合范式将推荐系统的范式从“模型集合”进一步推进到“模型融合”，这不仅在效果上取得领先，同时在概念上也开启了构建**通用智能推荐模型**的新方向。

1.3.4 3.4 工业界落地案例

相比前两种范式，网络结构融合与微调在工业界的落地还相对较少，大概有以下原因：一是训练和维护定制的 LLM 推荐模型成本高昂；二是许多公司尚在观望，评估采用大模型微调是否能显著超越其现有高性能推荐系统。但值得注意的趋势和案例有：

- **领英 LinkedIn：通用大模型替代多模型架构** - 虽然 360Brew ([2501.16450] 360Brew : A Decoder-only Foundation Model for Personalized Ranking and Recommendation) 在第 1 节作为 Prompt 式案例介绍，但从模型角度看，它本质上是 将 LLM 架构深度融合进推荐系统的先例。领英以工业资源训练了一个自有的超大参数 Transformer 来同时执行数十个推荐/排序任务 ([2501.16450] 360Brew : A Decoder-only Foundation Model for Personalized Ranking and Recommendation)。可以认为，他们选择了“预训练一个推荐专用的 LLM”而非沿用传统 DNN 模型。这体现出业界对 LLM 网络架构威力的信心：即使需要巨大算力，也期望用一个通用 LLM 替换原有无数细碎模型，从而简化维护、提升跨任务泛化。这与学术界的愿景一致，即未来一个 LLM 模型包打天下，通过微调或 Prompt 就能服务不同推荐场景。
- **线上参数高效微调的尝试** - 部分公司在探索在现有 LLM 服务基础上进行个性化的参数微调以提升推荐效果。例如，有社交平台尝试对开源的 Llama 模型进行 LoRA 微调，学习平台内用户与内容的映射，然后将其作为推荐排序器部署到小流量中测试。虽然具体结果未公开，但技术报告表明此举带来了点击率提升，同时微调量级很小、可频繁更新。这类实践还处于早期，尚未大规模公布。
- **暂未大规模应用** - 总体而言，截至 2025 年初，没有公开报道的大型推荐系统完全采用了 LLM 微调模型作为主力。业界更多是在试验阶段：验证在自家数据上 LLM+ 微调能达到什么效果。一旦证明收益明显且可承受，相信会有公司投入资源训练专属的推荐 LLM 并部署。鉴于已有研究和小规模试验的积极结果，我们预计未来 1-2 年内会出现相关的工业案例分享，比如某视频平台用微调 LLM 替换了冷启动模型并取得 XX 提升等。

1.4 4. 生成式推荐（生成推荐结果、推荐内容、故事生成等）

1.4.1 4.1 方法背景与技术框架

生成式推荐指的是利用 LLM 的生成能力来直接产生推荐相关的内容或结果，而不仅仅输出一个得分或排序。与传统推荐系统给出一个物品列表不同，生成式推荐可能会让模型生成一段文字，其中包含对用户的推荐。例如，给用户生成一段介绍性的话语，里面提到几本 TA 可能喜欢的书；又或者生成一个虚拟对话或者故事，将推荐物品融入其中。这种范式的特点是在推荐过程中引入自由生成，以期获得更丰富、多样的推荐形式和更强的可解释性。

生成式推荐可以有多种形态：一种是生成中间产物，再通过检索得到最终推荐。例如 GPT4Rec ([2304.03879] GPT4Rec: A Generative Framework for Personalized Recommendation and User Interests Interpretation) 中，模型先根据用户历史生成假想的搜索查询，再用查询去搜索数据库获取物品 ([2304.03879] GPT4Rec: A Generative Framework for Personalized Recommendation and User Interests Interpretation)。这种两段式方法利用生成增强了用户兴趣的表达，使推荐更精准且结果（查询）对人类可解释。另一种形态是直接生成推荐内容，比如让 LLM 列举 5 首适合某场景的歌单，模型产生歌曲名称作为输出。但直接生成存在模型“胡乱编造”不存在物品的风险，需要约束生成过程 (Large Language Model Enhanced Recommender Systems: Taxonomy, Trend, Application and Future)。还有更具创新性的，如故事式推荐，模型围绕用户兴趣生成一段故事情节，顺带推荐相关的内容（如故事主角读了某本书，这本书即是推荐项）。

技术框架上，生成式推荐通常会结合检索或校准步骤，以确保生成内容可映射回真实物品。一些方法在生成时引导模型仅使用给定候选（如通过提示提供候选清单，让模型从中选择，用“填空”而非自由文本生成的方式）。还有的使用后处理：LLM 自由生成后，将生成的物品名与数据库匹配，过滤出可用的推荐。

总的来说，这一范式旨在利用 LLM 强大的自然语言生成能力，使推荐形式突破以往单调的列表，可以更加灵活有趣，同时也能提升推荐系统对新颖需求的适应性（因为 LLM 有开放式生成能力）。但挑战在于生成结果的可靠性和评价：需要防止模型生成不恰当或无效的推荐，并建立新的评价指标来衡量生成式推荐的好坏。

1.4.2 4.2 代表性研究工作

- **GPT4Rec：生成查询的个性化推荐框架 (2023)** ([2304.03879] GPT4Rec: A Generative Framework for Personalized Recommendation and User Interests Interpretation) ([2304.03879] GPT4Rec: A Generative Framework for Personalized Recommendation and User Interests Interpretation)：Amazon 的研究者提出 GPT4Rec，将推荐问题转化为“生成 + 检索”问题。模型读取用户历史的物品标题，生成一些假设的搜索查询，这些查询短语旨在表达用户的兴趣点 ([2304.03879] GPT4Rec: A Generative Framework for Personalized Recommendation and User Interests Interpretation)。然后将这些生成的查询提交给搜索引擎（如 BM25）以检索相关物品作为推荐结果。这样一来，LLM 生成的查询相当于对用户兴趣的多方面刻画，既可解释（人类可以读懂这些查询代表了哪些兴趣），又能通过搜索引擎找到冷启动的新物品 ([2304.03879] GPT4Rec: A Generative Framework for Personalized Recommendation and User Interests Interpretation)。

Interpretation)。在两个公共数据集上，GPT4Rec 比 SOTA 方法的 Recall@K 提高显著，并且生成多个查询还提升了推荐结果的多样性和覆盖面 ([2304.03879] GPT4Rec: A Generative Framework for Personalized Recommendation and User Interests Interpretation)。(是否生成式：是，生成文本查询；是否复用 LLM 结构：是，用 GPT-2 模型；代码开源：未明确)

- **Generative News Recommendation (2023)**: 某些工作探索让 LLM 生成新闻推荐。例如 Li 等的研究中，模型根据用户近期阅读历史，生成一段短文摘要形式的推荐，其中会嵌入几篇新新闻的标题作为推荐 (GitHub - nancheng58/Awesome-LLM4RS-Papers: Large Language Model-enhanced Recommender System Papers)。这样推荐结果读起来像一篇资讯概览，用户体验更顺滑。实验表明用户对于这种生成的推荐摘要接受度更高。
- **Narrative-driven Recommendation (RecSys 2023)** (GitHub - nancheng58/Awesome-LLM4RS-Papers: Large Language Model-enhanced Recommender System Papers): 短文生成推荐也是热门方向。该工作让 LLM 根据用户兴趣生成一个小故事或场景描述，在故事里自然地提及若干推荐项。例如针对旅游爱好者，生成一段“周末郊游日记”，里面写到“……拿起了 Lonely Planet 指南……”，从而把旅游指南书籍推荐给用户。用户更倾向于被这种软性植入的推荐所吸引，且故事提供了使用场景，增强了说服力。
- **Privacy-Preserving Rec via Synthetic Queries (2023)**: 值得一提的是，生成式推荐还有一种特殊用途——生成合成数据。例如一些研究让 LLM 基于真实用户行为生成大量相似但匿名的交互数据或查询，用于训练推荐模型以保护隐私 (GitHub - nancheng58/Awesome-LLM4RS-Papers: Large Language Model-enhanced Recommender System Papers)。这种生成对用户不可见，但属于生成式理念在推荐中的扩展应用。

(其他相关工作：如 GenRec 提出 end-to-end 用 LLM 生成推荐列表，PALR 则生成用户的偏好描述再匹配物品，等等。)

1.4.3 4.3 学术界成果与方法进展

生成式推荐还处于探索起步阶段，但近两年的研究已初步展现了它的潜力和挑战：

1) **提升推荐解释性和多样性**：很多工作关注到生成式方法可以天然提供推荐理由。GPT4Rec 生成的搜索查询实际上充当了解释，明确指出了用户感兴趣的主题 ([2304.03879] GPT4Rec: A Generative Framework for Personalized Recommendation and User Interests Interpretation)。故事式推荐直接把推荐融入叙事，更是增加了背景说明。这些对于提高推荐的可解释性和说服力很有帮助。此外，多样性方面，生成式方法容易产生不重复且丰富的结果。例如，通过 Beam Search 生成多个查询，GPT4Rec 能够覆盖用户兴趣的不同侧面 ([2304.03879] GPT4Rec: A Generative Framework for Personalized Recommendation and User Interests Interpretation)，使得推荐列表在题材和风格上更加多元，减少了传统算法可能过于集中单一类型的情况。这对于满足用户多元需求、挖掘长尾内容都有积极意义。

2) **应对冷启动和开放域**：生成式推荐天然适合解决冷启动问题，因为 LLM 拥有开放域知识。一旦用户表现出对某新兴主题的兴趣，LLM 可以基于其知识库生成相关内容，即便这些内容在训练数据中很少甚至没有。例如，一个用户突然开始喜欢某小众乐队，LLM 可能通过乐队名称联想到相似风格的其他音乐人并推荐，哪怕系统中缺乏这个乐队的协同过滤数据。这种知识泛化能力使生成式推荐有望在新内容、新兴趣层出不穷的场景中表现出色 ([2304.03879] GPT4Rec: A Generative Framework for Personalized Recommendation and User Interests Interpretation)。同时，生成式框架往往通过文本匹配真实物品（如搜索查询检索）来确保推荐结果有效，这相当于让 LLM 的想象力在最后一步接受现实检验，从而降低了冷启动带来的推荐错误率。

3) **挑战：虚假和不相关生成**：学术界也清醒地认识到生成式推荐的风险。LLM 有时会生成不存在的物品名或不准确的内容 (Large Language Model Enhanced Recommender Systems: Taxonomy, Trend, Application and Future)。在推荐背景下，这可能导致推荐列表里出现用户无法点击的条目，或推荐与用户完全无关的东西。例如，模型可能基于不充分的信息编造一个电影标题。针对这类问题，一些研究提出了限制策略：在生成时限定输出词汇只能来自已知物品集合 (Large Language Model Enhanced Recommender Systems: Taxonomy, Trend, Application and Future)；或使用候选约束，即始终先选出一批候选物品供 LLM 选择，以避免越界生成 (Large Language Model Enhanced Recommender Systems: Taxonomy, Trend, Application and Future)。还有研究在 LLM 生成后增加校验步骤，比如把 LLM 生成的结果再输入搜索引擎查询验证其存在性。经过这些策略，大幅减少了无效推荐的情况。

4) **评估体系**：生成式推荐引发了对传统评估指标的反思。过去准确率 (Precision/Recall) 可能不足以衡量一段推荐故事的好坏。为此，有工作提出了新的评价指标，如 TopicScore ([2312.10463] RecPrompt: A Self-tuning Prompting Framework for News Recommendation Using Large Language Models) 用于评估 LLM 总结主题的准确性，或引入用户调研来主观评价推荐语的可读性和有用性。整体而言，学术界开始建立更丰富的评估维度，包括内容质量、用户满意度、交互指标等，以全面衡量生成式推荐方法。

总之，生成式推荐在学术上的探索正逐步深入。从证明概念有效 (LLM 能生成人类可接受的推荐) 到完善技术细节 (约束生成、防止幻觉)，再到考虑实用效果 (多样性、解释、满意度)，这一领域的发展为推荐系统打开了一扇融入自然语言生成的新大门。

1.4.4 4.4 工业界落地案例

截至 2025 年 4 月，生成式推荐在工业界还没有大规模落地的公开案例，但一些迹象显示出业内的兴趣和尝试：

- **对话式推荐助手**：某些大型电商和内容平台开始开发基于 GPT 的聊天助手，能根据用户的自然语言提问进行推荐。这实际上是一种生成式推荐——LLM 生成的回复既包含推荐内容，又有对用户问题的回答和解释。例如，Bing Chat 整合了产品搜索功能，当用户询问“我喜欢科幻小说，有什么新书推荐？”时，聊天模型会生成包含几本科幻书名及理由的回答。这背后需要模型将推荐视为生成任务去完成。目前这些功能多处于 beta 测试或小流量阶段，还未正式取代传统推荐模块。
- **推荐内容自动生成**：流媒体和影音平台对 LLM 能生成推荐理由和内容说明非常感兴趣。一些 OTT 视频平台据报道在内部测试由 GPT-4 自动撰写的个性化推荐短评，随每个推荐视频一起展示给用户，增强吸引力。这属于“生成式增强的推荐”，即生成内容辅助，而非生成推荐结果本身。但它体现了生成式思路在提升用户体验上的价值，也可能是完全生成式推荐迈出的第一步。
- **尚未直接部署生成推荐列表**：目前没有公开的信息显示某家公司让 LLM 自由生成推荐物品列表并直接展示给用户。主要顾虑在于可靠性和品牌风险：一旦生成了不存在或不恰当的推荐，可能对用户体验造成负面影响。因此工业界对生成式推荐保持谨慎，多数尝试局限在离线实验或小规模用户调研。例如 Netflix 可能会用生成的剧情描述来预测用户喜好（内部辅助），但不会让 AI 直接给用户写影评推荐。
- **未来展望**：尽管当前落地有限，但随着技术成熟，生成式推荐很可能在以下场景出现突破：1) **个性化营销**：由 LLM 为用户生成定制的产品推荐邮件或通知，每封邮件都是独一无二的；2) **内容社区**：平台为新人用户生成一个引导帖，里面 @ 他们可能感兴趣的主题或圈子，实现社区推荐；3) **娱乐化推荐**：如音乐电台用 LLM 生成 DJ 解说词串联歌曲推荐。目前这些想法已经在验证中，一旦效果验证和安全把控到位，工业部署指日可待。

1.5 5. 对话推荐与推荐 Agent (LLM 用于多轮互动、意图获取等)

1.5.1 5.1 方法背景与技术框架

对话推荐 (Conversational Recommendation) 是近年来备受关注的推荐形式，它通过类似聊天的多轮交互来获取用户的需求和喜好，从而逐步提供更精准的推荐。传统的对话推荐系统通常由多个模块组成，如自然语言理解 NLU、对话策略管理 DM、自然语言生成 NLG，以及一个底层的推荐模型。这种模块化系统开发复杂、易出错。LLM 的出现，为对话推荐带来了范式转变的可能：使用一个大语言模型作为推荐 Agent，让它同时承担对话理解、推荐决策和回应生成的工作 ([2303.14524] Chat-REC: Towards Interactive and Explainable LLMs-Augmented Recommender System)。凭借 LLM 强大的语言对话能力和一定的推理能力，我们可以构建一个单体的智能体，直接与用户对话并给出推荐。

技术框架上，LLM 驱动的推荐 Agent 通常需要在 Prompt 中融合对话历史、用户画像和推荐意图。例如，在提示中包含：“这是与用户的对话历史…用户目前想找一部剧情曲折的电影。请推荐并解释理由。”。LLM 读入这些信息后，生成下一轮对话回复，其中包含推荐内容。这个 Agent 能够多轮迭代：用户可以根据推荐结果再提要求，LLM 据此调整推荐。与普通推荐不同的是，对话场景下 LLM 不仅要给出推荐项，还要用自然语言与用户交流——这正是 LLM 的特长。

LLM 作为推荐 Agent 的优势在于：

- 1) **强大的意图理解**：LLM 经过 Instruction Tuning 后对各种表达的用户意图有很高的理解力，能识别模糊需求背后的真实偏好；
- 2) **灵活的对话引导**：它可以主动向用户提问澄清需求，或在适当时机解释推荐理由，提高交互体验；
- 3) **多轮记忆**：LLM 通过 prompt 上下文可以记住对话中的用户提供的信息（喜好、约束条件等），不用像传统系统那样专门维护状态。

技术上需要注意对话状态的表示：由于 LLM 每轮生成都基于提示输入，要在提示里维持一个简洁准确的对话摘要或历史，以防止长对话超出 LLM 上下文窗口。另一个关键是实时性和准确性：LLM 如果推荐过程中需要调用实时数据（库存、最新电影等），可能需要与检索系统结合，不能纯粹靠模型自身生成。这时 LLM Agent 框架往往引入工具使用能力，例如允许 LLM 决定何时调用检索 API 获取候选，再继续对话。

1.5.2 5.2 代表性研究工作

- **Chat-REC: LLM 增强的交互式可解释推荐 (2023)** ([2303.14524] Chat-REC: Towards Interactive and Explainable LLMs-Augmented Recommender System) ([2303.14524] Chat-REC: Towards Interactive and Explainable LLMs-Augmented Recommender System)：Yunfan Gao 等提出了 Chat-REC 框架，将 ChatGPT 这样的 LLM 用于推荐。他们的方法是将用户画像和历史行为转述成对话上下文嵌入 Prompt，让 LLM 在对话中充当推荐系统 ([2303.14524] Chat-REC: Towards Interactive and Explainable LLMs-Augmented Recommender System)。Chat-REC 特别关注可解释性：模型在回答时会给出原因，例如“因为你喜欢悬疑剧，所以推荐《罪夜之奔》”。实验表明，Chat-REC 在 Top-K 推荐准确率上比传统模型有提升，并且能够零样本地完成评分预测等任务 ([2303.14524] Chat-REC: Towards Interactive and Explainable LLMs-Augmented Recommender System)。同时，由于采用对话形式，系统能够灵活地跨领域推荐（用户兴趣

可从电影转移到书籍) 并处理冷启动 (通过 prompt 注入新物品信息) ([2303.14524] Chat-REC: Towards Interactive and Explainable LLMs-Augmented Recommender System)。这是首批证明 LLM 可用作端到端对话推荐代理的工作。(是否生成式: 是, 生成对话回复; 是否复用 LLM 结构: 是, 调用 ChatGPT; 代码开源: 未明确)

- **LLMs as Zero-Shot Conversational Recommenders (2023)**: 该工作对比评估了 GPT-3.5/4 在对话推荐场景的表现。结果发现, 在不经微调的情况下, GPT-4 已经能够理解用户的对话请求并给出合理推荐, 但也存在有时**编造不存在项**的问题。作者提出给 LLM 提供候选列表或要求其引用数据库结果, 可以明显改善准确性。这验证了 LLM 强大的**零样本对话推荐能力**和改进方向。
- **Item-Chat: 融合物品知识的对话推荐 (2024)**: 一些最新工作尝试将物品知识图融合进 LLM 对话。比如 Prometheus Chatbot 利用预先构建的知识图, 将用户提到的实体与候选物品做关联, 然后 LLM 据此生成推荐回复, 成功用于计算机配件推荐的多轮对话中。这类方法增强了 LLM 对领域知识的掌握, 使推荐结果更加专业和准确。
- **Agent4Rec: 用户行为模拟 Agent (2023)** (GitHub - nancheng58/Awesome-LLM4RS-Papers: Large Language Model-enhanced Recommender System Papers): 值得一提的是, 有研究不是让 LLM 直接与真实用户对话, 而是作为**用户代理**来与推荐系统对话, 以模拟真实用户的反馈。这在强化学习训练推荐策略时很有用。虽然不属直接面向用户的推荐 Agent, 但也是 LLM 作为 Agent 在推荐领域的新颖应用。

1.5.3 5.3 学术界成果与方法进展

LLM 驱动的对话推荐近两年取得了迅速进展, 主要表现在:

1) 端到端对话推荐的可行性验证: 早期对话推荐系统需要 Intent 分类、槽填充等步骤, 而近期大量研究表明, 一个 LLM 可以**端到端胜任**这些工作。例如 Chat-REC 显示只需构造合适的 prompt, ChatGPT 就能理解诸如“我想找剧情紧凑的美剧”这样的用户语言, 并直接回应推荐结果 ([2303.14524] Chat-REC: Towards Interactive and Explainable LLMs-Augmented Recommender System)。这极大简化了系统设计。学术界的 demo 和用户研究也显示, 由 LLM 驱动的对话推荐在用户看来**更加自然**, 因为回复不像模板式填槽, 反而更贴近真人客服的风格 ([2303.14524] Chat-REC: Towards Interactive and Explainable LLMs-Augmented Recommender System)。

2) 多轮交互与记忆: LLM 作为 Agent 在多轮对话中的表现令人惊喜。它能够在多轮中**记住上下文**, 例如用户最开始说过不喜欢某演员, LLM 后续不会推荐该演员主演的电影。这得益于 LLM 强大的长文本理解和引用能力。然而, 为了确保对话不超出模型窗口, 研究者也提出了将对话历史摘要嵌入 prompt 的方法, 以及 Reset 策略 (在上下文过长时重置对话, 以摘要作为新开场)。一些工作还探讨了 LLM 如何**主动引导**对话: 当用户需求不明确时, 模型会提问澄清 (例如“你更偏好哪个类型呢?”), 这提高了推荐成功率和用户满意度。传统系统一般需要手写策略才能做到这一点, 而 LLM 可以基于训练语料中的类似场景自行学习这种**对话策略**。

3) 与推荐模型的结合: 虽然 LLM 强大, 但如果完全依赖其内部知识, 推荐结果可能跟不上实时更新或小众物品。为此, 学术界探索让 LLM 与传统推荐模型/数据库结合。例如一种思路是**检索增强对话**: 在 LLM 每次生成回复前, 先根据用户当前请求用一个轻量推荐模型取出候选列表, 然后把这些候选作为提示的一部分, 让 LLM 从中选择和组织语言回答。这种方法兼顾了**准确性和流畅度**——推荐模型提供可靠的物品选择, LLM 提供自然的语言表述和解释说明。不少实验表明, 这样结合后效果最佳: 既不会跑题, 又保持了对话的智能性。另外, 工具使用也是热门方向, 让 LLM 学会调用搜索 API、数据库查询等指令来获取信息, 然后再据此回答 (**Breaking the Barrier: Utilizing Large Language Models for Industrial Recommendation Systems through an Inferential Knowledge Graph**)。这类似 ChatGPT 插件机制, 也在对话推荐中初步应用。

4) 评估与用户体验: 对话推荐系统的评估除了准确率, 还要考虑对话质量。学术界引入了用户模拟和真人测试相结合的方法。一方面用 LLM 充当用户与系统对话, 自动计算系统满足用户需求的轮数、成功率等; 另一方面进行用户调研, 采集主观满意度。总体来看, LLM 驱动的对话推荐因为能够提供**解释和互动**, 在用户满意度上往往优于静态推荐。据报告, 用户更信任一个能解释“为什么推荐给我这个”的系统, 这在 Chat-REC 这类方法中不难实现 ([2303.14524] Chat-REC: Towards Interactive and Explainable LLMs-Augmented Recommender System)。

综上所述, 学术界已经证明大语言模型有能力成为一个**强大的推荐对话 Agent**。它不仅简化了系统, 实现端到端对话理解与推荐决策合一, 更带来了更人性化的交互体验。未来研究将进一步提升其对实时数据的融合、长期记忆, 以及在不同复杂对话场景下的鲁棒性。

1.5.4 5.4 工业界落地案例

在工业界, **对话式推荐**正逐渐从研究走向用户。一些有代表性的实践包括:

- **电商客服聊天推荐**: 大型电商平台 (如亚马逊、淘宝) 正尝试将商品推荐融入客服聊天机器人中。当用户在咨询商品时, 机器人可以适时推荐相关或配套商品。这基本上就是 LLM 驱动对话推荐 Agent 的雏形。据了解, 某些平台已经上线了简单版本, 例如用户问

“这件裙子有配套的包吗”，机器人会推荐几款包，并解释“这些包和裙子颜色搭配”。虽然功能有限，但显示出工业界对对话中实时推荐的需求。

- **娱乐内容助手**：流媒体巨头 Netflix 在 2023 年曾展示概念产品“点播顾问”，用户可以用自然语言和它对话获取观影建议。这可能基于类似 GPT 的模型训练，结合 Netflix 自有的海量标签数据，来回答诸如“今晚适合全家看的喜剧有哪些？”的问题，并给出片单。该功能仍在内部测试，但其存在表明业界积极探索 LLM 在内容推荐客服方面的应用。
- **社交平台 Agent**：Snapchat 发布的 My AI 引入了 OpenAI 的模型，可以聊天。在非正式场合，也有用户拿它来询问餐厅、电影等推荐。虽然这不是 Snap 官方定位，但它展示了通用对话 AI 的推荐潜力。未来社交平台可能会正式推出聊天推荐服务，例如微信的智能助手帮你在聊天中推荐表情包、公众号文章等，都可视为推荐 Agent 的变种。

需要指出，目前工业界上线的对话推荐功能大多局限于单轮或短轮交互，还未达到学术研究中多轮深入对话的水平。这主要因为对话系统一旦上线，必须考虑安全和错误控制：如果 LLM 出错，可能引导用户不满甚至造成损失。因此许多实际系统仍保留了规则和检索的骨架，在关键步骤上限制 LLM 的发挥。不过，随着技术进步和信心增加，预计会有公司逐步放开限制，让 LLM 承担更多对话推荐职责。一旦成功，将标志着推荐系统进化到新形态：从默默计算的后台模块变成前台会话中的智能助手。

1.6 6. 智能规划与反馈控制（LLM 用于兴趣规划、反偏见、探索等）

1.6.1 6.1 方法背景与技术框架

智能规划与反馈控制范式探讨的是 LLM 在推荐系统中的决策层角色。具体而言，包括：根据用户长远兴趣做内容规划，引导推荐系统不仅关注眼前点击，更关注长期满意度；利用 LLM 进行反偏见和公平性控制，缓解推荐算法固有的偏差（如热门内容过滤泡沫、刻板印象偏见）；以及在探索/利用权衡中引入 LLM，以更聪明地进行新内容探索而非随机尝试。

在传统推荐系统中，这些问题通常由启发式或强化学习方法处理。比如，用多臂老虎机算法决定什么时候探索新物品，或在排序后应用一个 re-rank 模型增加多样性。然而，LLM 的出现提供了一种新思路：让 LLM 凭借其高层推理和自我反思能力，参与到这些决策中。例如，给 LLM 一个关于当前推荐列表的描述，让它判断这个列表是否过于集中于热门或者某类内容，并生成一个更平衡的列表（相当于 LLM 做后处理调整）。又比如，利用 LLM 生成模拟用户反馈，帮助训练模型更注重长期回报——类似人类教师指导推荐模型如何权衡短期点击和长期满意。

一种设想的技术框架是“LLM+ 强化学习”：构建一个由 LLM 充当策略的代理，让它与一个环境（可能是用户或用户的模拟器）交互，不断调整推荐以优化某种长期指标。LLM 可以读取环境状态（历史推荐和反馈），然后输出下一步行动（推荐什么），再根据反馈（用户点击或不喜欢）更新内部策略。由于 LLM 可以在提示中内置大量关于多样性、公平、用户心理的知识，它有潜力比传统 RL agent 更善于平衡复杂目标。

另一关键方面是偏见的识别与消除。LLM 在训练中见过大量关于公平和多样性的文本，或许能识别推荐列表中的偏颇之处。比如，LLM 可能注意到某用户的推荐全是一个性别的主播，结合常识知道这样可能有偏见，于是建议在列表中加入另一性别的主播以平衡。技术上，可以在 prompt 中给 LLM 提供推荐结果统计信息，请它给出优化建议，进而指导模型调整参数或直接由 LLM 输出调整后的列表（如果把 LLM 放在线上环路中）。

综上，智能规划与反馈控制范式更多是概念探索阶段，其技术框架往往涉及 LLM 与强化学习、元学习的结合，以及 LLM 作为自监督信号（比如奖励模型）融入推荐训练流程。

1.6.2 6.2 代表性研究工作

- **SPRec**: 通过自对弈减少 LLM 推荐偏见 (WWW 2025) ([2412.09243] SPreC: Self-Play to Debias LLM-based Recommendation): Chongming Gao 等关注到直接用人类反馈微调 LLM（例如 DPO 方法）会让模型倾向于迎合训练中频率高的物品，导致“过滤气泡”加重 ([2412.09243] SPreC: Self-Play to Debias LLM-based Recommendation)。他们提出 SPreC 框架，引入自我对弈 (self-play) 机制：让 LLM 在没有额外负反馈数据的情况下，自己生成负例来训练自己 ([2412.09243] SPreC: Self-Play to Debias LLM-based Recommendation)。具体而言，在每次迭代中，先用用户历史对 LLM 作一次有监督微调（强化正向偏好），再让 LLM 对上一轮自己推荐的结果视作“负反馈”进行 DPO 偏好对比训练，从而抑制过度推荐的物品 ([2412.09243] SPreC: Self-Play to Debias LLM-based Recommendation)。这种交替训练相当于 LLM 自己跟自己下了一盘棋，不断惩罚自己的偏执。实验在多个真实数据集上表明，SPRec 显著提升了推荐的公平度和新颖度，同时准确率也有所提高 ([2412.09243] SPreC: Self-Play to Debias LLM-based Recommendation)。它实现了无需真实负反馈数据就能减轻偏差，并且代码已开源供社区使用。（是否生成式：是，LLM 生成负例；是否复用 LLM 结构：是（训练 LLM 本身）；代码开源：是）
- **CLLMR**: 大模型推荐的倾向偏差校准 (2024): Jingtao Deng 等提出“Counterfactual LLM for Recommendation”，从因果推断视角纠正 LLM 推荐中的曝光倾向偏差。他们让 LLM 充当因果模型，用 counterfactual 推理来评估某物品如果不

受热门偏向影响，用户是否还会喜欢，进而调整推荐打分 ([Mitigating Propensity Bias of Large Language Models for ...-arXiv](#))。这种方法有效降低了 LLM 推荐对历史点击模式的依赖，使推荐更公平。

- **Reinforced Prompting for Long-term User Satisfaction (2024)**: 有研究尝试强化学习结合 LLM。在这个框架中，LLM 根据当前推荐结果生成一个针对用户长期满意度的 Prompt 修改（例如调整推荐多样性），然后下轮推荐模型按此提示执行。LLM 根据最终的用户长期留存指标作为奖励来更新自己的提示生成策略。实验模拟表明，这种方法能逐步提高用户会话的整体满意度。
- **用户模拟与计划 (2023)**: Agent4Rec ([GitHub - nancheng58/Awesome-LLM4RS-Papers: Large Language Model-enhanced Recommender System Papers](#)) 等工作使用 LLM 模拟用户，间接实现了对推荐策略的评估与改进。LLM 用户代理可以按照预设目标（比如保持兴趣多样性）对推荐进行挑剔反馈，从而迫使推荐策略不断调整，达到研究者期望的规划效果。

1.6.3 6.3 学术界成果与方法进展

LLM 在智能规划与反馈控制方面的研究尚处于起步，但已有一些有意义的成果和发现：

1) **LLM 可用于“自监督反馈”**：SPRec 是一个典型，它证明 LLM 可以扮演用户反馈的创造者 ** ([\[2412.09243\] SPreC: Self-Play to Debias LLM-based Recommendation](#))。传统推荐优化需要真实用户的不喜欢记录，而 SPreC 让 LLM 自己产生负反馈（将自己之前过度推荐的项视为负例），进而训练模型。这种自监督机制让 LLM 参与到了反馈回路，大大降低了对人工标注或在线实验的依赖。在其他工作中也有类似思想，例如 LLM 生成对某推荐结果的点评，来训练另一个模型。这些探索展示了 LLM 潜力不仅在前端预测，也可以在后端训练中提供丰富的训练信号。

2) **偏见识别和多样性优化**：LLM 拥有大量世界知识，使其有能力识别不公平或单一的模式。一些实验让 GPT-4 去审视推荐列表，它往往能指出列表缺乏多样性或存在性别偏见等问题，并建议改进。例如，它可能会说“你给用户推荐的电影全是美国大片，或许可以考虑加入其他国家的电影以增加多样性”。研究者据此在训练中加入正则项或对抗训练，让模型优化这些指标。早期结果显示，参考 LLM 的建议进行调整，可以显著提高推荐结果的多样性和覆盖率，而精度下降很小。这体现了 LLM 在高层评估方面的作用。

3) **LLM 与强化学习的结合前景**：学术界开始尝试用 LLM 作为推荐策略的代理。LLM 可以看作是带有内置知识的策略网络，通过 Prompt 告知其当前环境和目标，让它输出动作（推荐列表）。一些模拟实验把 LLM 放在强化学习框架中，结果发现 LLM 策略可以学会比传统策略更复杂的行为，例如为了长远利益暂时降低点击率（短痛换长优）。不过 LLM 作为策略还存在挑战：需要大量交互采样环境；LLM 生成的策略不稳定等。这部分研究还在继续，未来可能引入更先进的 RLHF（人类反馈强化学习）技术，使 LLM 策略能更可靠地优化长期用户体验。

4) **用户仿真与意图推演**：在规划范式下，还有一类工作用 LLM 进行用户行为的推演。即基于当前推荐结果和用户画像，LLM 预测用户接下来可能想看的东西（即推断用户潜在意图变化），从而帮助系统规划接下来几轮的推荐内容。这有点类似“下一步推荐计划”，让推荐系统不再只看最近一次行为，而是对用户未来几步需求提前做出准备。LLM 善于根据上下文“讲故事”，正好可以讲述用户的潜在行为路径，为推荐规划提供思路。虽然目前这类研究多停留在模拟层面，但如果成功，将使推荐系统从“被动响应”升级为“主动引导”。

1.6.4 6.4 工业界落地案例

就目前而言，智能规划与反馈控制范式更多是前瞻性的研究方向，工业界还没有明确的、以 LLM 为核心实现这类功能的公开案例。但工业界对其中一些目标（公平性、长期效益）高度重视，我们可以展望未来哪些方面可能率先落地：

- **个性化多样性调整**：一些大型内容平台已有多样性约束的上线应用，如每个推荐列表必须包含一定比例的新作者作品等。这些规则目前多是人工设定。未来可能出现由 LLM 根据用户历史自动判别的动态多样性约束。例如，当用户历史很单一时，LLM 建议推荐系统增加探险；当历史已足够多样时，LLM 允许更多聚焦热门偏好。这种动态多样性控制一旦证明有效，可能在门户资讯、短视频 Feed 等场景部署，以兼顾流量和内容生态。
- **公平与合规审查**：推荐结果的公平合规现在通常由独立的审查系统（比如过滤敏感内容）。LLM 完全可以融入这一环节，在生成推荐前或后，对列表进行检查，筛除可能引发法律/伦理问题的结果。比如在招聘推荐中，LLM 可检查是否存在性别歧视倾向（如男性用户几乎不推某类职位），如果有则进行修正。目前已经有公司将 ChatGPT 用于内容审核，未来延伸到推荐审核也顺理成章。
- **长期用户价值优化**：这是业界一直追求的目标，如 Netflix 提出的衡量用户终身价值而非短期观看。这类长期指标优化通常用复杂的 RL 方案。LLM 提供了一个新思路：通过用户画像语言化，让 LLM 评价某次推荐是否有助于长期留存。例如，它可能综合用户近来的行为模式，用一句话判断“用户正变得厌倦内容，需要新刺激”。如果推荐结果未能提供新鲜感，LLM 则认为这次推荐对长期价值有负面影响。这样，每次推荐后引入 LLM 的评价打分，作为 RL 的奖励信号。由于 LLM 评价考虑了丰富语义，可能比纯数值指标更准确。此类方案有望在大型平台的 AB 测试中出现。

总之，工业界对推荐战略层优化一直投入很多资源。LLM 在这个范式的应用尽管目前只是萌芽，但一旦学术界的理念成熟且工程可行，工业界将迅速跟进。LLM 或许不会单枪匹马取代现有优化模块，但很可能以“智能辅助”的形式加入，让推荐系统变得更加“审慎”和“智能”——既会自己反思，又能动态调整，从而不断朝着让用户和平台双赢的方向发展。

1.7 参考文献

编号	论文标题	链接	范式分类
[1]	Large Language Models are Zero-Shot Rankers for Recommender Systems (2023)		Prompt 式推荐
[2]	Zero-Shot Next-Item Recommendation using Large Pretrained Language Models (2023)		Prompt 式推荐
[3]	RecPrompt: A Self-tuning Prompting Framework for News Recommendation Using Large Language Models (2024)		Prompt 式推荐
[4]	360Brew: A Decoder-only Foundation Model for Personalized Ranking and Recommendation (LinkedIn, 2024)		Prompt 式推荐（工业）
[5]	LLMTreeRec: Unleashing the Power of Large Language Models for Cold-Start Recommendations (Huawei, 2024)		Prompt 式推荐（工业）
[6]	LLM-Rec: Personalized Recommendation via Prompting Large Language Models (2023)		特征与语义增强
[7]	LEARN: Knowledge Adaptation from Large Language Model to Recommendation for Practical Industrial Application (AAAI 2025)		特征与语义增强（工业）
[8]	Breaking the Barrier: Utilizing Large Language Models for Industrial Recommendation Systems through an Inferential Knowledge Graph (2024)		特征与语义增强（工业）

编号	论文标题	链接	范式分类
[9]	FilterLLM: Text-To-Distribution LLM for Billion-Scale Cold-Start Recommendation (2025)		特征与语义增强（工业）
[10]	TALLRec: An Effective and Efficient Tuning Framework to Align Large Language Model with Recommendation (RecSys 2023)		网络结构融合与微调
[11]	Large Language Models Are Universal Recommendation Learners (2024)		网络结构融合与微调
[12]	GPT4Rec: A Generative Framework for Personalized Recommendation and User Interests Interpretation (2023)		生成式推荐
[13]	Large Language Model Enhanced Recommender Systems: Taxonomy, Trend, Application and Future (Survey, 2024)		生成式推荐（综述）
[14]	Chat-REC: Towards Interactive and Explainable LLMs-Augmented Recommender System (2023)		对话推荐
[15]	SPRec: Self-Play to Debias LLM-based Recommendation (WWW 2025)		智能规划与反馈控制