Breaking the Modality Barrier: Universal Embedding Learning with Multimodal LLMs

1 阶段一：文本判别知识蒸馏

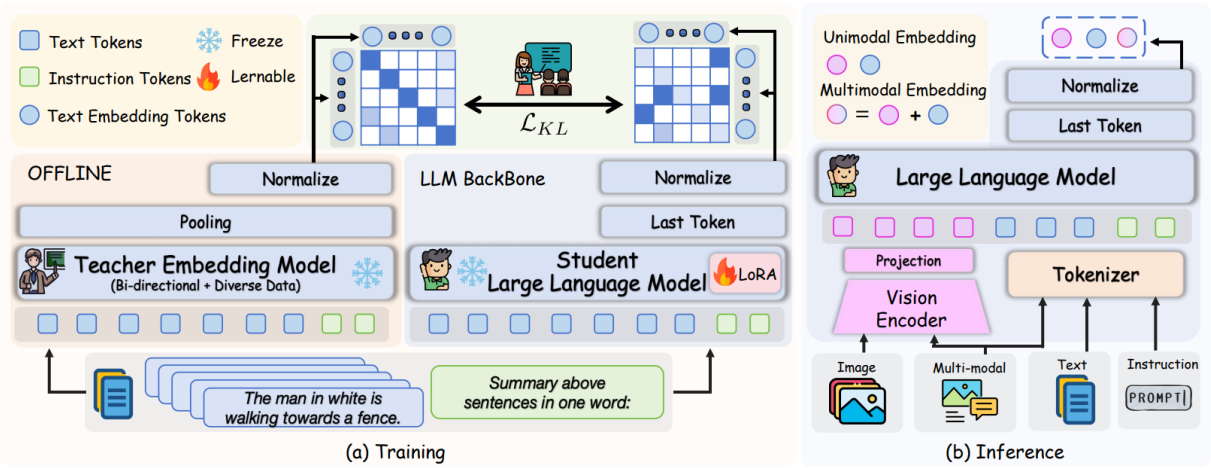

用纯文本数据来增强 MLLM 中 LLM 的嵌入能力，用了 273k 个句子对。

- teacher：基于 LLM 的嵌入模型 NV-Embed V2（对比训练中移除了 causal mask）离线批量产出文本的 emb
- student：MLLM 中把 LLM 部分剥离出来，输入 prompt `Summary the above sentences in one word: \n`，最后一个 token 的 emb 当成输出
- 蒸馏：teacher 和 student 间算 KL 散度，LoRA 训练

推理时：

- 单模态输入：通过 prompt 的设置，决定只走对应的 vision/text encoder
- 图片 + 文字输入：通过 prompt，各自过模型，然后把输出的 2 个 emb 进行融合

2 阶段二：困难负样本增强指令微调

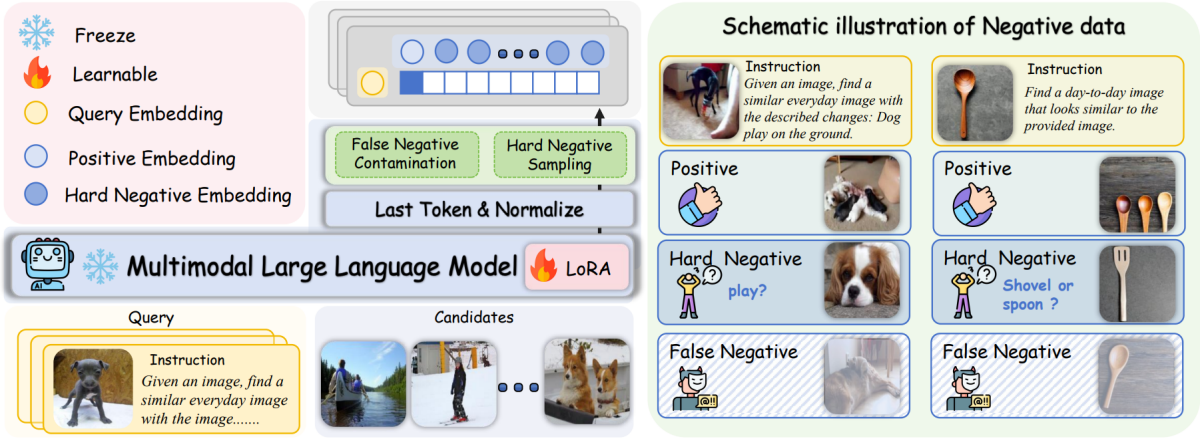

拿多模态的样本对来提升图文之间的对齐，用了 662k 个 pair 对：

- query: img+prompt
- doc: img

样本处理：

- 干掉 false negative：有些负样本和 query 的相似度太高了，干掉
- 增加 hard negative：除了正例和前面的 false negative 外，在负样本里找出 k 个和 query 最像的，当成 hard negative

loss 是 infoNCE，然后用 QLoRA 来微调